

Mendelova univerzita v Brně
Provozně ekonomická fakulta

Řízení autonomního agenta pomocí neuroevoluce

Diplomová práce

Vedoucí práce:
Ing. Jiří Lýsek, Ph.D.

Bc. Martin Hnátek

Brno, 2018

Zde bude zadání diplomové práce

Rád bych zde poděkoval svému vedoucímu Ing. Jiří Lýskovi, Ph.D. za jeho cenné rady a čas, který mi věnoval při řešení této práce.

Čestné prohlášení

Prohlašuji, že jsem práci: **Řízení autonomního agenta pomocí neuroevoluce** vypracoval samostatně a veškeré použité prameny a informace uvádím v seznamu použité literatury. Souhlasím, aby moje práce byla zveřejněna v souladu s § 47b zákona č. 111/1998 Sb., o vysokých školách a o změně a doplnění dalších zákonů (zákon o vysokých školách), ve znění pozdějších předpisů, a v souladu s platnou *Směrnicí o zveřejňování vysokoškolských závěrečných prací*.

Jsem si vědom, že se na moji práci vztahuje zákon č. 121/2000 Sb., autorský zákon, a že Mendelova univerzita v Brně má právo na uzavření licenční smlouvy a užití této práce jako školního díla podle § 60 odst. 1 autorského zákona.

Dále se zavazuji, že před sepsáním licenční smlouvy o využití díla jinou osobou (subjektem) si vyžádám písemné stanovisko univerzity, že předmětná licenční smlouva není v rozporu s oprávněnými zájmy univerzity, a zavazuji se uhradit případný příspěvek na úhradu nákladů spojených se vznikem díla, a to až do jejich skutečné výše.

V Brně dne 3. ledna 2019

.....

Abstract

Autonomous agent control using neuroevolution

Thesis describe theory behind neuroevolution. Then it describes both design and creation of simulated environment for autonomous agent and its training with library Neataptic in environments with various difficulty. Thesis also describes process of designing frontend for visualization of results and backend for faster training of agents. At the end it describes resulting agents and proposes enhancements to existing solution.

Key words:

NEAT, AI, MachineLearning, Agent, Javascript

Abstrakt

Řízení autonomního agenta pomocí neuroevoluce

Tato práce představuje teoretický základ neuroevoluce. Zahrnuje také návrh tvorbou simulačního prostředí, pro autonomního agenta a jeho natrénování s pomocí knihovny Neataptic v různě obtížných podmínkách. Popisuje také tvorbu frontendu pro snadnou vizualizaci a serverové části pro rychlé učení. Na závěr se zabývá vyhodnocením natrénovaných agentů a návrhem možných zlepšení.

Klíčová slova:

NEAT, AI, MachineLearning, Agent, Javascript

Obsah

1	Úvod a cíl práce	12
1.1	Úvod do problematiky	12
1.2	Cíl práce	12
2	Literalní řešerše	13
2.1	Neuronové sítě	13
	Neuron	13
	Vrstva	13
	Aktivační funkce	13
	RELU	15
	Rekurentní neurony	16
2.2	Genetické algoritmy	16
	Princip	16
	Kódování	16
	Křížení	17
	Mutace	17
	Selekce	17
	Využití	18
2.3	NEAT	18
	Genotyp a fenotyp	18
	Mutace	19
	Křížení	19
2.4	Rozšíření algoritmu NEAT	19
	Instinct	19
	odNEAT	20
	rtNEAT	20
	HyperNEAT	20
	cgNEAT	20
2.5	Alternativy k neuroevoluci	21
2.6	Využití algoritmu NEAT	21
3	Použité technologie	22
3.1	Docker	22
3.2	Databáze	22
3.3	Prezentační část	22
3.4	Serverová část	23
	NodeJS	23
	Bull	23
	Sequelize	23
3.5	Monitorování	23
	Grafana	23

	Arena	23
	Portainer	24
3.6	Simulace	24
	PIXI.js	25
	Neataptic	25
	NPM a YARN	25
	P2.js	25
3.7	CES	25
	Komponenta	25
	Entita	26
	System	26
4	Metodika	27
5	Analýza problému	28
5.1	Funkční požadavky	28
	Simulace	28
	Vizualizace	28
	Experimenty	28
5.2	Nefunkční požadavky	28
6	Návrh řešení	30
6.1	Simulace	30
	Diagram tříd	31
	Entity	31
	Komponenty	31
	Systémy	31
6.2	Klientská část	32
	Zobrazení algoritmu v reálném čase	32
	Přehrávač	33
6.3	Serverová část	34
	První verze	34
	Druhá verze	34
	Databáze	35
6.4	Návrh experimentů a simulačního prostředí	35
	Simulační prostředí	36
	Agent	36
	Možné konfigurace agenta	37
	Fitness funkce	38
7	Implementace	39
7.1	Simulace	39
	Fitness funkce	39
	Simulační prostředí	40

7.2	Serverová část	43
	Konfigurovatelnost	43
	Výpočetní cluster	44
	Docker swarm	46
	Problémy implementace	47
	Monitorování stavu	47
7.3	Uživatelská část	48
	Vizualizace	48
	Přehrávač	49
7.4	Nasazení serverové části	50
	Grafana	51
7.5	Nasazení uživatelské části	51
8	Experimenty	52
8.1	První stupeň - silnice ve tvaru I	52
	Konfigurace bez rozšíření	52
	Konfigurace s rozšířeními	53
8.2	Druhý stupeň - silnice ve tvaru I s překážkami	54
	Konfigurace bez rozšíření	54
	Konfigurace s rozšířeními	55
8.3	Třetí stupeň - Okruh	56
	Konfigurace bez rozšíření	56
	Konfigurace s rozšířením	56
8.4	Zhodnocení	58
9	Možná vylepšení	59
10	Závěr	60
11	Literatura	61
	Přílohy	63
A	Přihlašovací údaje k PostgreSQL	64
B	Obsah CD	65

Seznam obrázků

1	Příklad křížení	17
2	Příklad mutace	17
3	Genotyp a fenotyp u algoritmu NEAT převzato z (STANLEY, Kenneth O, Risto MIIKKULAINEN., 2002, s. 9)	18
4	Mutace v NEAT převzato z (STANLEY, Kenneth O, Risto MIIKKULAINEN., 2002, s. 10)	19
5	Křížení v NEAT. Převzato z (STANLEY, Kenneth O, Risto MIIKKULAINEN., 2002, s. 12)	20
6	Webové aplikace Arena	24
7	Rozhraní aplikace portainer	24
8	Schéma závislostí	30
9	Diagram tříd	31
10	Drátkový návrh zobrazení algoritmu v reálném čase	33
11	Drátkový návrh přehrávače	33
12	První verze serverové části	34
13	Sekvenční diagram komunikace se serverem	35
14	Schéma databáze	35
15	Řízení agenta	37
16	Neuronová síť agenta	37
17	Silnice ve tvaru písmene I	40
18	Silnice ve tvaru I s překážkami	41
19	Silnice ve tvaru horizontálně obráceného L	41
20	Silnice ve tvaru L	42
21	Silnice ve tvaru -	42
22	Silnice ve tvaru zrcadlově obráceného L	42
23	Horizontálně a vertikálně obrácené L	43
24	Porovnání rychlosti clusteru s jedním PC	46
25	Schéma distribuovaných výpočtů	46
26	Kontrolní panel v aplikaci grafana	48
27	Uživatelské rozhraní klientské části	49
28	Rozhraní přehrávače	50
29	Průběh evaluace - I bez rozšíření	52
30	Neuronová síť - I bez rozšíření	53
31	Průběh evaluace - I s rozšířeními	53
32	Neuronová síť - I s rozšířeními	54
33	Graf průběhu fitness - bez překážek	54
34	Neuronová síť - silnice ve tvaru I s překážkami bez rozšíření	55
35	Graf průběhu fitness funkce - s překážkami	55
36	Neuronová síť - silnice ve tvaru I s překážkami s rozšířeními	56
37	Průběh fitness - Okruh bez rozšíření	56
38	Neuronová síť - Okruh bez rozšíření	57

39	Průběh fitness funkce - Okruh bez rozšíření	57
40	Neuronová síť - Okruh s rozšířením	57

Seznam tabulek

1	Použitý hardware	44
2	Naměřená data	45

1 Úvod a cíl práce

1.1 Úvod do problematiky

S růstem výpočetního výkonu a rozvojem **GPUGPU** (paralelizace výpočtů na grafické kartě) se neuronové sítě ukázaly jako mocný nástroj pro řešení složitých problémů na které standardní metody umělé inteligence nestačily.

Další oblastí umělé inteligence, které nárůst masivní paralelizace prospěl, je oblast genetických algoritmů a různých jiných metaheuristik, které mohou s nárůstem výpočetního výkonu v rozumném čase pokrýt stále větší stavový prostor a jsou tedy schopné rychle řešit stále složitější problémy.

Neuroevoluce propojuje oba přístupy a využívá je ke generování topologii neuronových sítí a nastavení jejich vah. Výsledkem je neuronová síť, jejíž architektura lépe popisuje daný problém a lze jí aplikovat i na problémy na které by klasické neuronové sítě aplikovat nešly. Jedná se například o problémy, u kterých je těžké získat trénovací data a nelze tedy neuronovou síť natrénovat klasickými metodami, jako je například gradientní sestup.

Jedním z problémů, které výše zmíněné pokroky v oblasti umělé inteligence umožnily je problematika autonomních vozidel, kterou se v současné době zabývá mnoho technologických firem. Tato diplomová práce se tohoto tématu také jemně dotýká tvorbou simulovaného prostředí a trénováním agenta (automobilu) v různých podmínkách.

1.2 Cíl práce

Cílem této práce je aplikovat neuroevoluci pro učení autonomního agenta. Toto zahrnuje návrh a vytvoření vhodného simulačního prostředí. Poté na simulovaném prostředí navrhnout a provést sérii experimentů, které slouží k zjištění limitů učících schopností algoritmu NEAT.

2 Literalní rešerše

Teoretická část práce seznamuje čtenáře s popisem algoritmu NEAT a algoritmů ze kterých vychází.

2.1 Neuronové sítě

Neuronové sítě jsou model strojového učení, který je volně založený na principu zvířecího mozku (PATTERSON, Josh. 2017, s. 41).

Neuron

Neuron je základní výpočetní jednotka neuronových sítí, která je definovaná jako suma všech jejích vstupů a aplikace aktivační funkce.

$$g(\sum_{i=0}^N \theta_i \cdot x_i + b)$$

Kde:

1. x_i - i-tý vstup do neuronu
2. g - aktivační funkce
3. θ - skrytá váha pro daný vstup
4. b - bias neuronu

Na tomto místě je vhodné podotknout, že výše uvedená notace vychází z přednášek Andrew Y. Ng a je jen jednou z mnoha běžně uváděných.

Vrstva


Vrstva je skupina neuronů se stejnou aktivační funkcí.

Aktivační funkce

Aktivační funkce se používá pro definování výstupu a zavedení nelinearity. Bez nich by byla neuronová síť schopna aproximovat pouze n-dimenzionální rovinu. (PATTERSON, Josh. 2017, s. 65)


Dalším využitím je omezení výstupních hodnot. Například aktivační funkce sigmoid se s oblibou používá u výstupní vrstvy neuronových sítí určených ke klasifikačním problémům, protože je to relace $\mathbb{R} \rightarrow \{0..1\}$, která se dá jednoduše jako "jistota" neuronu, že se jedná o výstup, který neuron reprezentuje. Podobně se dá uvažovat i o funkcích jako je například softmax a tanh, které také najdou hojně využití u klasifikačních problémů.

Lineární funkce Vrací vstup, tak jak je. Využití najde především u vstupní vrstvy neuronové sítě a u neuronových sítí, které řeší regresní typy úloh.



$$f(x) = x$$


Sigmoid Sigmoid je aktivační funkce, která je schopná potlačit extrémní hodnoty a převést je do rozsahu 0 - 1.



$$f(x) = \frac{1}{1 + e^{-x}}$$

Tanh


Tanh je funkce obdobná sigmoidu. Hlavní rozdíl mezi ní a sigmoidem je ten, že její obor je v rozmezí -1 a 1 hodí se proto i pro záporná výstupy, které vyžadují záporná čísla. (PATTERSON, Josh. 2017, s. 67)



$$f(x) = \tanh(x)$$

RELU

RELU je aktivační funkce, která je podobná lineární aktivační funkci s tím rozdílem, že pokud vstupní hodnota nepřesáhne určitého prahu výstupem je 0. Její hlavní výhodou je to, že zabraňuje problémům s takzvaným explodujícím gradientem (PATTERSON, Josh. 2017, s. 69)



$$f(x) = \begin{cases} x & x \geq 0 \\ 0 & x < 0 \end{cases}$$

Rekurentní neurony

Speciální druh neuronů, který si dokáže zapamatovat a reagovat na sekvenci vstupů. Rekurentní neurony značně rozšiřují možnosti neuronových sítí. S nimi je možné řešit složité úlohy typu strojového překladu nebo sémantické vyhodnocování textu.

V praxi se setkáváme s dvěma druhy neuronů a to LSTM a novější GRU. LSTM a GRU jsou si velmi podobné s jedním podstatným rozdílem. U GRU bylo prokázáno, že je značně rychlejší.

Další běžně používaným typem rekurentních neuronových sítí jsou sítě typu NARX, které se hojně používají pro predikci časových řad (P. MENEZES JR., JOSE A GUILHERME BARRETO. 2006, s. 1).

2.2 Genetické algoritmy

Genetické algoritmy slouží k řízenému prohledávání stavového prostoru založené na teorii evoluce. (KOZA, JOHN R., 1992, s. 17)

Princip

Základní myšlenka spočívá ve vygenerování náhodných jedinců (řešení problému) a jejich postupné zlepšování s pomocí operací křížení a mutace. Proces zlepšování genomů probíhá na základě jeho hodnocení (fitness).

Samotný algoritmus pak lze rozdělit na následující kroky (MITCHELL, Melanie., 1996, s. 12)

1. Vygeneruj náhodnou populaci o n chromozomech
2. Pro každý chromozom spočítej jeho fitness
3. Opakuj dokud není splněná podmínka ukončení
 - a) Vyber pár chromozomů na základě jejich ohodnocení (selekce)
 - b) Proveď spojení chromozomů (křížení)
 - c) S určitou pravděpodobností mutuj daného jedince (mutace)
4. Nahraď současnou populaci populací, která vznikla předchozím krokem
5. Jdi na krok 2

Kódování

Někdy se mu též říká genotyp je způsob zápisu řešení problému. Je důležité zároveň uvést pojem fenotyp který označuje vlastní řešení úlohy.


Existuje mnoho různých kódování a každý má své výhody a nevýhody. Většinou se snažíme vybírat kódování, které dobře reprezentuje daný problém. Zde je seznam několika nejpoužívanějších kódování (HYNEK, Josef., 2008, s. 42-43):

1. Binární - řetězec bitů, který může například reprezentovat jednu nebo více numerických hodnot.
2. Reálná čísla - Jedno nebo více reálných čísel
3. Permutační - Sekvence čísel nebo symbolů používané například pro řešení problému obchodního cestujícího

Křížení

Křížení je operátor, který kombinuje dva jedince do jednoho. Jedinec, který vzniká přebírá genetickou informaci od obou jedinců v určitém poměru. Jeho implementace je závislá na použitém kódování.

Příkladem může být obrázek 1 ve kterém je ilustrováno tzv. jednobodové křížení (HYNEK, Josef., 2008, s. 50) při kterém dochází k rozdělení obou genomů ve stejném bodě a spojením vzniklých podřetězců do nového genomu.




Obrázek 1: Příklad křížení

Mutace

Mutace náhodně modifikuje chromozom a zavádí tak do populace variaci. Díky tomu se může algoritmus dostat z lokálního extrému.

Existují různé varianty mutace, která se provádí v závislosti na daném kódování.

Například u binárního kódování se může jednat o náhodnou inverzi některého z bitů genomu viz obrázek 2.



Obrázek 2: Příklad mutace

Selekce

Selekce je proces výběru dvou jedinců na něž jsou později aplikovány genetické operátory jako je křížení a mutace.

Využití

Genetické algoritmy naleznou využití v mnoha optimalizačních úlohách. Příkladem může být experiment, který zahrnoval použití gramatické evoluce pro vytvoření regresních modelů pro datasety CASY3 a CASY5 (LÝSEK Jiří, ŠŤASTNÝ Jiří, 2014, s. 2-9).

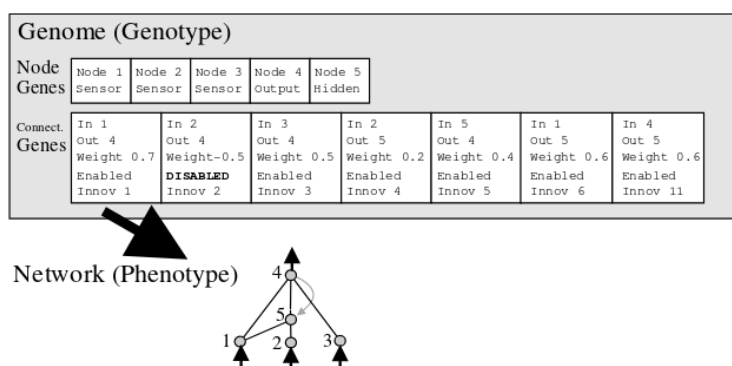
2.3 NEAT

NEAT (neuroevolution of augmenting topologies) kombinuje neuronové sítě s genetickými algoritmy. Hlavní výhodou této metody je, že generuje jak topologii neuronové sítě, tak její váhy. Výsledkem může být neuronová síť jejíž rozložení lépe popisuje řešený problém.

Algoritmus probíhá stejně jako běžný genetický algoritmus. Rozdílem je použitý fenotyp a operátory mutace a křížení, které se nad ním provádí.

Genotyp a fenotyp


Genotyp a fenotyp je ilustrován na obrázku 3. Genotyp obsahuje jak údaje o jednotlivých neuronech, tak informace o topologii sítě. Metadata, která se týkají topologie neuronové sítě jsou údaje o spojení (IN, OUT), váha samotného spojení (weight), informace týkající se toho, zda je spojení použito v fenotypu (ENABLED/DISABLED) a inovační skóre. Inovační skóre je číslo, které reprezentuje pořadí ve kterém se daný gen objevil v fenotypu (STANLEY, Kenneth O, Risto MIIKKULAINEN., 2002, s. 9).



Obrázek 3: Genotyp a fenotyp u algoritmu NEAT převzato z (STANLEY, Kenneth O, Risto MIIKKULAINEN., 2002, s. 9)

Mutace

Jak již bylo zmíněno nad fenotypem lze provádět různé operace včetně operátoru mutace, který provede náhodnou změnu fenotypu s nadějí, že změna povede k zlepšení řešení. V případě algoritmu NEAT je operátor mutace ilustrován na obrázku 4. Na obrázku je vidět, že mutace může buď přidat další spojení nebo další neuron. V případě, že je přidáván nový neuron je mu přiřazeno náhodné spojení, které je označeno znakem DISABLED (STANLEY, Kenneth O, Risto MIIKKULAINEN., 2002, s. 10).



Obrázek 4: Mutace v NEAT převzato z (STANLEY, Kenneth O, Risto MIIKKULAINEN., 2002, s. 10)

Křížení


Posledním operátorem používaným při algoritmu NEAT je operátor křížení. Operátor křížení ilustruje obrázek 5. Křížení probíhá na základě inovačního čísla. Spojení se stejným inovačním číslem jsou náhodně zděděny z rodičovských genů. Je tu také šance na převzetí genů, které vytváří spojení nenacházející se v jednom z rodičů. Tyto geny jsou převzaty pouze z rodiče, který má větší fitness. Při křížení je také náhodná šance, která může převzatý genom vypnout (STANLEY, Kenneth O, Risto MIIKKULAINEN., 2002, s. 12).

2.4 Rozšíření algoritmu NEAT

Jelikož je algoritmus NEAT v současnosti předmětem aktivního výzkumu existuje pro něj mnoho rozšíření. Tato sekce se bude zabývat některými z nich.

Instinct

Instinct rozšiřuje původní algoritmus o rekurentní neurony. Rozšíření tak umožňuje případnému agentovi reagovat nejen na okamžitou situaci ale i na předchozí události ve světě. Tento fakt značně rozšiřuje možnosti neuronových sítí, které jsou generované tímto algoritmem ale zároveň je třeba mít na paměti, že se tímto značně



Obrázek 5: Křížení v NEAT. Převzato z (STANLEY, Kenneth O, Risto MIIKKU-LAINEN., 2002, s. 12)

zvětšuje prohledávaný stavový prostor a dochází tím k zvýšené časové náročnosti na získání vhodných výsledků.

odNEAT

Varianta algoritmu NEAT aplikovaná na distribuované online učení skupiny autonomních robotů (SILVA, FERNANDO, PAULO URBANO, LUÍS CORREIA a ANDERS L. CHRISTENSEN, 2015, s. 1).

rtNEAT

Rozšíření, které se zaměřuje na neuroevoluci agentů v reálném čase.

HyperNEAT

HyperNEAT rozšiřuje neuroevoluci o možnost vytváření velmi velkých neuronových sítí (STANLEY, KENNETH O., DAVID B. D'AMBROSIO a JASON GAUCI., 2009, s. 1).

cgNEAT

Rozšíření zaměřující se na generování náhodného obsahu. Obdobně jako tomu je například u GAN sítí.

2.5 Alternativy k neuroevoluci

Neuroevoluce není jediný přístup, který je dostupný k řešení problému typu trénování autonomního agenta.

Příkladem může být rozsáhlý obor zabývající se zpětnovazebním učením (reinforcement learning). Při zpětnovazebním učení máme agenta, který se nachází v prostředí nad kterým může vykonávat různé akce. Agent může před vykonáním akce pozorovat stav prostředí na základě čehož se rozhoduje, jakou akci vykoná. Po provedení některé se prostředí nějakým způsobem mění a agent dostává zpětnou vazbu v podobě odměny. Algoritmus zpětnovazebního učení se snaží agenta řídit tak, aby maximalizoval jeho odměnu. Příkladem může být zajímavý výzkum (MNIH, VOLODYMYR, KORAY KAVUKCUOGLU, DAVID SILVER, et al., 2015, s. 1), který zkouší s pomocí zpětnovazebního učení vytvořit agenta, který hraje různé počítačové hry.

2.6 Využití algoritmu NEAT

Algoritmus NEAT a jeho varianty předmětem aktivního výzkumu. Své využití nalézá hlavně v oblasti robotiky a řešení pro počítač obtížných problémů jako je například hraní počítačových her. Příkladem může být nedávný výzkum provedený laboratořemi umělé inteligence společnosti Uber, který pojednává o použití algoritmu NEAT k naučení umělé inteligence, která je schopná hrát jednoduché hry na herní platformě Atari (PETROSKI SUCH, FELIPE a kol., 2018, s. 1).

3 Použité technologie

Tato kapitola poskytuje stručný přehled technologií použitých při řešení diplomové práce. Při volbě technologií bylo rozhodnuto, že se bude jednat o webovou aplikaci především díky možnosti snadné distribuce aplikace (stačí statická webová stránka), tak možnosti spustit aplikaci na platformě NodeJS, která má nástroje pro její rychlejší vyhodnocení.

3.1 Docker

Docker je nástroj, který umožňuje vytvářet tzv. kontejnery. Kontejner poskytuje izolované softwarové prostředí ve kterém lze spouštět jednu nebo více aplikací. V praxi to umožňuje snadné nasazení libovolné aplikace bez ohledu na aktuální konfiguraci hostitelského systému. V této práci se používá především pro snadné nasazení serverové části za stejných podmínek na různých hardwarových platformách. Ačkoliv existují konkurenční řešení (LXD, KVM, ...) byl vybrán právě docker, protože

3.2 Databáze

Výsledky experimentů bude nutné někde zapsat. Jako vhodné řešení se jeví relační databáze. S důvodů hw omezení je na ní několik praktický nefunkčních požadavků:

- Musí být schopná běžet na architektuře arm
- Musí být ACID
- Musí být schopná obsloužit více klientů (čtení a zápis)

Z výše uvedených důvodů, z důvodu předchozích zkušeností a s ohledem na to, že se jedná o nekritickou část systému byl vybrán databázový systém PostgreSQL.

PostgreSQL je populární databázový systém, který nabízí robustní open-source alternativu i ke komerčním řešením. Navíc splňuje všechny podmínky stanovené na začátku této sekce.

3.3 Prezentační část

Pro tvorbu moderních webových aplikací je dobré zvolit jeden z mnoha frameworků pro jejich tvorbu. Po zvážení dostupných možností byl zvolen framework **Vue.js** populární JavaScriptový framework pro snadnou tvorbu uživatelských rozhraní. Důvodem jeho volby byla pro autora snadno pochopitelný princip a relativní systémová nenáročnost, která je uváděna na webových stránkách autorů tohoto frameworku (Vue.js, 2014).

3.4 Serverová část

Pro serverovou část byla vybrána platforma NodeJS spolu s dalšími dodatečnými technologiemi popsanými v této sekci.

NodeJS

NodeJS je open-source interpret jazyku JavaScript. Využití najde při psaní serverových aplikací v JavaScriptu a jiné případy, kdy je třeba spustit kód napsaný v javascriptu mimo prohlížeč. Lze ho využít například pro spouštění testů při CI (continuous integration) nebo pro tvorbu vysoce serverových aplikací v jazyce JavaScript.

Narozdíl od běžného JavaScriptu obsahuje rozšířenou standardní knihovnu pro snadnou tvorbu serverových aplikací. Tato standardní knihovna umožňuje například javascript kódu prací se soubory na hostitelském systému, což je něco, co není z bezpečnostních důvodů v klasickém JavaScriptu, který běží v prohlížeči možné.

Bull

Bull je knihovna pro NodeJS, která poskytuje frontu úkolů založenou na populární in-memory databázi Redis. V serverové části se používá pro distribuované výpočty.

Sequelize

ORM knihovna pro NodeJS používá se především pro zápis výsledků do databáze.

3.5 Monitorování

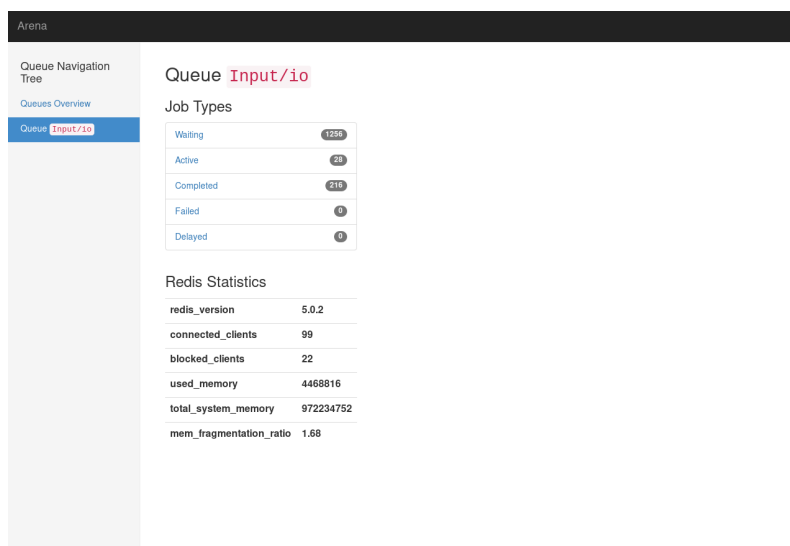
Výstupy z použitých databázových systémů (PostgreSQL a Redis pro **Bull** bylo třeba monitorovat. PostgreSQL, kvůli průběhu experimentů a Redis při procesu ladění výsledné aplikace. Pro tento účel jsou použity níže popsané aplikace.

Grafana

Grafana umožňuje snadnou vizualizaci dat z databáze. Děje se tak definováním vhodných dotazů a volbou grafu, který je reprezentuje. V základní instalaci je na výběr několik druhů zobrazení a v případě potřeby je lze rozšířit s pomocí přídavných pluginů.

Arena


Arena je webová aplikace pro správu a zobrazení aktuálního stavu fronty úkolů poskytované knihovnou bull.



Obrázek 6: Webové aplikace Arena

Portainer

Portainer je webová aplikace pro zobrazení aktuálního stavu a správu instance dockeru a docker swarmu.



Obrázek 7: Rozhraní aplikace portainer

3.6 Simulace

Na simulaci, která poslouží k evaluaci agenta se lze dívat jako na jednoduchou hru. Z tohoto důvodu byly nejdříve zváženy různé herní enginy dostupné pro javascript. Ve

všech případech bylo ovšem naraženo na to, že jsou příliš provázány s frontendovou částí, což by znemožnilo pozdější nasazení na **Node.JS**. Z tohoto důvodu byly vybrány následující technologie. Výčet nezahrnuje knihovnu CES, která si zaslouží vlastní sekci.

PIXI.js

Grafická knihovna pro snadné vykreslování nad HTML značkou canvas, která byla zavedena ve verzi 5. Obaluje jak klasické vykreslovací API, tak modernější WebGL.

Neataptic

Knihovna implementující samotný algoritmus NEAT ve variantě instinct. Důvodem volby této knihovny byl obrovský potenciál, který právě algoritmus instinct představuje. Přidává totiž potenciálnímu agentovi užitečný nástroj a to paměť. Bude tak zajímavé sledovat, jak jí použije.

NPM a YARN

NPM i Yarn jsou kolíčkovací systémy pro javascript. Hlavní rozdíl mezi NPM a Yarn je, že Yarn stahuje balíčky paralelně. Je tedy značně rychlejší oproti NPM.

P2.js

Zkoušený problém vyžaduje použití fyzikální simulace. To pomůže jak se snadněji implementací simulace vozidla, tak s detekcí kolizí a implementací případných vzdálenostních senzorů.

Z tohoto důvodu byl vybrán P2.js, který má oproti ostatním fyzikálním enginům několik výhod. První výhodou je idiomaticnost jeho API. Na rozdíl od některých jiných enginů, které jsou založené na knihovně pro programovací jazyk c Box2D. Byl P2.js napsán v javascriptu. Další výhodou je přítomnost před-připraveného fyzikálního modelu vozidla. Toto značně šetří implementační čas, jelikož korektní implementace fyziky vozidla je náročný úkol sám o sobě.

3.7 CES

Je knihovna, která implementuje tzv. ECS (entity component system). Problematika ECS je tak rozsáhlá, že si zaslouží vlastní sekci. Používá se především ve hrách a nabízí určitý způsob, jak se dívat na herní objekty a logiku. Myšlenka je taková, že vše lze rozdělit do níže uvedených podsekcí.

Komponenta

Komponenty bývají jednoduché datové struktury, které vyjadřují vlastnosti entity u níž jsou přiřazeny.

Entita

K entitě se dá přiřadit jedna nebo více komponent (vlastností). Entita tak může představovat libovolný herní objekt.

Příkladem může být vozidlo, které může být reprezentováno složením fyzikální, grafické a ovládací komponenty. Při správné implementaci níže zmiňovaných systému lze pak na jakoukoliv entitu, která má tyto komponenty nahlížet jako na auto.

Je důležité si uvědomit, že na rozdíl od klasického systému dědičnosti je možné entity snadno rozšířit tak, že do nich přidáme další komponenty. Můžeme například k entitě auta přiřadit komponentu životy a udělat ho tak zranitelným.

System

Systém provádí určité akce nad entitami, které mají dané komponent. Chceme-li například propojit grafickou reprezentaci s fyzikálním enginem, můžeme si napsat systém, který po kroku fyzikálního enginu vyhledá všechny entity, které mají grafickou a fyzikální komponentu upraví pozice a rotaci všech grafických objektu tak, aby byla identická s pozicí a rotací fyzikálních objektů, které jsou k nim přiřazeny.

4 Metodika

Na začátku je potřeba provést analýzu problému s ohledem na požadavky stanovené konzultacemi s vedoucím. Návrh bude také zahrnovat experimenty, které budou s neuroevolucí provedeny.

Po návrhu bude následovat implementace daného řešení. Popis řešení bude přidán do této práce. V průběhu implementace bude také kód a návrh postupně upravován na základě požadavků, které se mohou objevit až při implementaci navrženého řešení.

Po implementaci bude následovat realizace a vyhodnocení experimentů popsaných v návrhu.

Na závěr proběhne vyhodnocení řešení s návrhem možných zlepšení.

5 Analýza problému

Tato kapitola se zabývá analýzou funkčních a nefunkčních požadavků pro softwarové řešení. Požadavky vznikaly na základě konzultace s vedoucím a vlastní invencí.

5.1 Funkční požadavky

Funkční požadavky jsou rozděleny do několika kategorií.

Simulace

Vyhodnocování agenta bude probíhat jeho nasazením v simulovaném prostředí. Fitness bude pak vyhodnocena na základě jeho akcí v prostředí.

- Testovací prostředí musí být pro všechny agenty stejné
- Fitness by měla být zjistitelná kdykoliv v průběhu simulace
- Simulace by měla být konfigurovatelná
- Možnost změny obtížnosti simulace pro agenta
- Měla by existovat možnost spuštění více instancí simulace v rámci jednoho programu

Vizualizace

Průběh algoritmu je třeba zobrazit.

- Je třeba provést grafickou vizualizaci fyzikální simulace
- Při zobrazení by mělo být možné vyčíst stav agenta (fitness, senzory, ...)
- Možnost vizualizace průběhu simulace v reálném čase (například pro její demonstraci v předmětu VUI2)

Experimenty

Práce zahrnuje vyhodnocování agenta v různých podmínkách z tohoto vychází následující požadavky:

- Schopnost vyhodnocovat více konfigurací zároveň
- Přehledné zobrazení vývoje různých simulací pro pozdější srovnání

5.2 Nefunkční požadavky

Spolu s funkčními požadavky jsou na řešení kladeny také požadavky nefunkční.


- Škálovatelnost - Možnost spustit a vykreslit libovolné množství simulací

-
- Rychlost simulace - Simulace by měla být schopná samostatně běžet alespoň rychlostí 30 snímků za vteřinu.
 - Portabilita - bylo třeba zajistit, aby šlo kód rozběhnout v různých platformách v různých konfiguracích.
 - Robustnost - Simulace by si měla poradit s neočekávanými vstupy, jako je třeba **NaN**, který vychází z neuronové sítě.

6 Návrh řešení

Tato kapitola obsahuje návrh řešení založený na požadavcích identifikovaných v předchozí kapitole. Na základě těchto požadavků byl návrh rozdělen do dvou projektů a to webového frontendu, který slouží jako rozhraní ukazující průběh simulace v reálném čase a serverové části, která slouží pro rychlý výpočet simulace bez vykreslování na platformě Node.js.

Jelikož obě části budou používat stejný simulační kód bylo rozhodnuto, že bude samotná simulace vytvořena jako softwarová knihovna. Tuto závislost ilustruje obrázek 8.



Obrázek 8: Schéma závislostí

6.1 Simulace

Z obrázku 8 je zřejmé, že simulační kód spojuje obě části dohromady. Je tedy důležité, aby byl navržený tak, aby jej bylo co nejjednodušeji integrovat s oběma řešeními.

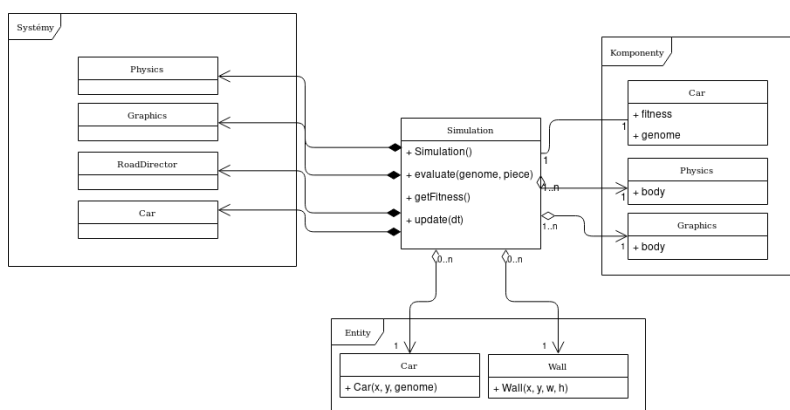
Na základě těchto požadavků a podmínek, které jsou stanoveny v předchozí kapitole byl vytvořen následující návrh:

Simulace obsahuje vlastní engine, který je navržen v duchu ECS (**Entity component system**), podrobný popis lze nalézt v sekci 3.7. Při návrhu simulace bylo rozhodnuto o implementaci vlastního engine oproti použití existujících řešení je několik. Hlavním důvodem byl požadavek na separaci grafické části simulace od části výpočetní, který vznikl z potřeby spouštění aplikace na platformě Node.js kvůli serverové části.

Z použití ECS vyplývá, že se všechny komponenty nalezené v simulaci dají rozložit na systémy, komponenty a entity. Pro lepší představu o implementaci je níže uveden přehled všech systému, entit a komponent použitých v simulaci.

Diagram tříd

Níže popsaný návrh doplňuje diagram tříd, který zobrazuje jejich návaznost a zároveň také do návrhu zavádí třídu **Simulation**, která celou simulaci schovává za jednoduché rozhraní a umožňuje snadnou integraci simulace do různých aplikací.



Obrázek 9: Diagram tříd

Entity

Simulace obsahuje následující entity (prvky simulace):

PhysicsGroup Seskupuje fyzikální entity do jedné pro snadnou manipulaci s nimi.

RoadPart Entita, která obaluje jednu nebo více překážek tak, aby se s nimi dalo snadno pohybovat. Používá se pro tvorbu složitějších dílů vozovky.

Car Reprezentuje samotné vozidlo, obsahuje jak jeho grafickou reprezentaci, tak kompletní logiku a fyzikální model.

Komponenty

Simulace obsahuje následující komponenty:

- **Car** obsahuje všechny potřebné informace o agentovi. Toto zahrnuje vše od neuronové sítě, která je použita pro jeho řízení po ovládání jednotlivých kol agenta.
- **Graphics** komponenta, která obsahuje grafické informace pro **Pixi.js**.
- **Physics** komponent, která obsahuje fyzikální entity pro **P2.js**

Systemy

Návrh simulace obsahuje následující systémy:

Car systém, který se stará o ovládání agenta a částečně o vyhodnocování jeho fitness. Pro každý snímek prožene vstupy (v závislosti na konfiguraci) neuronovou síť a na základě jejích výstupů řídí agenta.

Graphics grafický systém, který slouží především k překreslování entit.

Physics krokuje fyzikální engine a synchronizuje grafickou reprezentaci s fyzikální entitou. Tento proces probíhá pro každý snímek a skládá se z přiřazení nové rotace a pozice pro grafickou entitu.

RoadDirector Road director se stará o generování nekonečného prostředí pro agenta. Děje se tak na základě předefinovaných dílů vozovky z nichž každý zaplňuje celou obrazovku simulace. V případě, že agent dorazí až na konec obrazovky, je mu určen nový navazující dílek. Agent je pak přesunut na opačnou stranu obrazovky a zároveň je vyměněn díl na kterém se nachází. Tento postup a důvod jeho návrhu je rozepsaný v sekci 6.4.

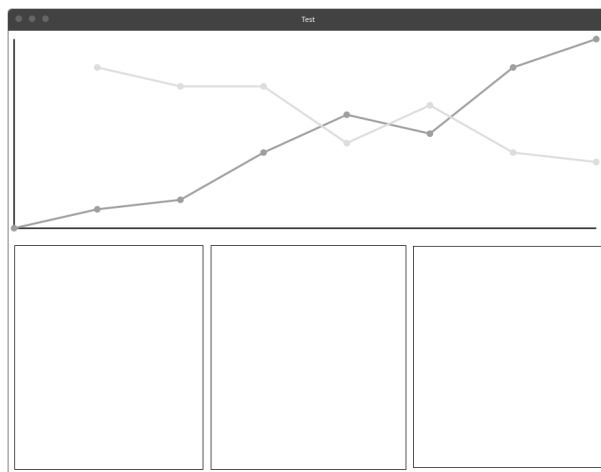
6.2 Klientská část

Klientská část je webové rozhraní, které vzniklo z požadavků na vizualizaci a ověření funkčnosti simulační knihovny.

Z požadavků vyšla aplikace, která obsahuje 2 rozdílné obrazovky a to první, která slouží pro zobrazení a simulaci vývoje algoritmu v reálném čase. Další slouží pro zpětné přehrávání již vygenerovaných genomů.

Zobrazení algoritmu v reálném čase

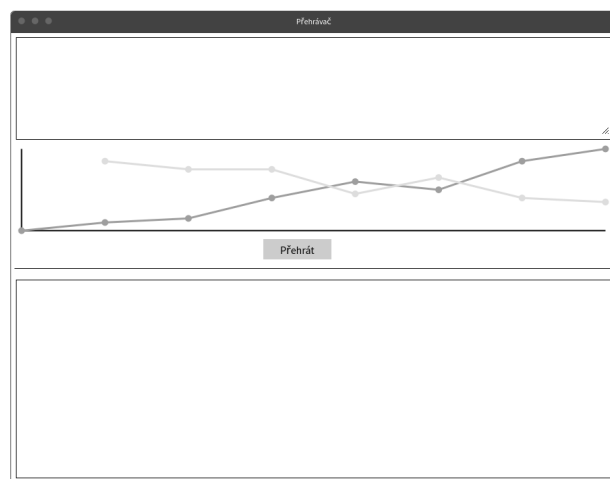
Zobrazení algoritmu v reálném čase nabízí jak nadhled na průběh algoritmu s pomocí grafu, který bude zobrazovat dosaženou fitness jednotlivých generací a přímým zobrazením průběhu jednotlivých jedinců (v náčrtu zobrazeno jako obdélníky).



Obrázek 10: Drátkový návrh zobrazení algoritmu v reálném čase

Přehrávač

Cílem přehrávače je zobrazit průběh již vyhodnoceného jedince. K tomuto má textové pole s informacemi o jedinci, tlačítko pro spouštění přehrávání a plocha na které je vizualizován průběh agenta.



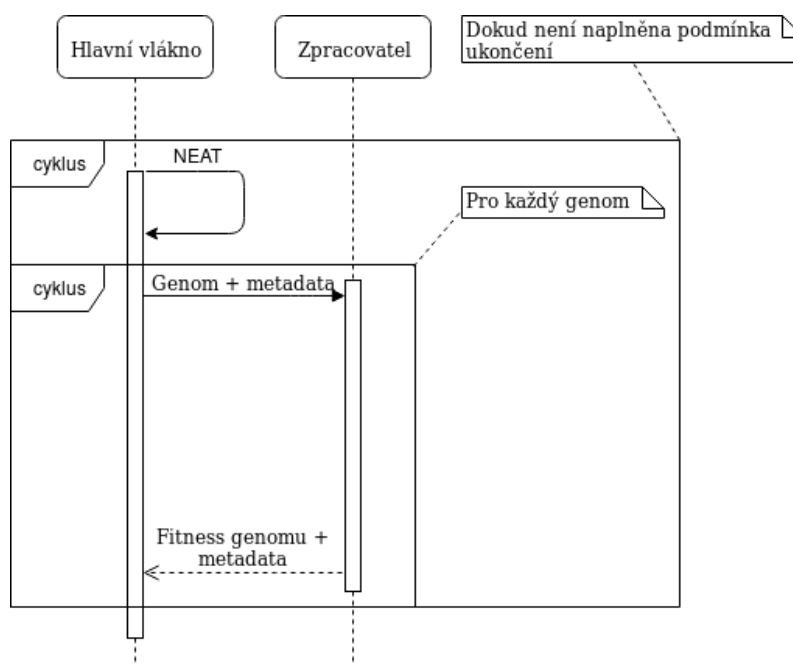
Obrázek 11: Drátkový návrh přehrávače

6.3 Serverová část

Serverová část byla nakonec navržena a vytvořena ve dvou na sebe navazujících verzích.

První verze

Je ilustrovaná na obrázku 12. Návrh první verze popisuje jednoduchou aplikaci, která rozkládá vyhodnocování jednotlivých genomů mezi jednoho nebo více zpracovatelů. Každý zpracovatel běží ve vlastním vlákne a zátěž je tedy rozložena mezi dostupná jádra procesoru. Zpracovatel po vyhodnocení genomu vrací hlavnímu vláknu fitness daného jedince. Ten si ho uloží a po vyhodnocení všech jedinců tímto způsobem provede algoritmus NEAT. Tento proces se opakuje do té doby, než dojde k naplnění ukončujících podmínek (maximální počet generací) nebo přerušení programu.




Obrázek 12: První verze serverové části

Druhá verze

Druhá verze rozšiřuje návrh o možnost rozložení výpočtů mezi více počítačů. Byla navržena poté, co bylo zjištěno, že předchozí verze nebyla schopná vyhodnotit dostatečné množství genomů dostatečně rychle.

Pracuje dle diagramu 25, kde je vidět, že klient zadává do fronty úkoly (genom a nastavení simulace). Jednotliví zpracovatelé (počítače v clusteru), si je z ní vyberou, genomy a vyhodnotí a hodnotu fitness funkce pošlou zpět na klienta. Toto je ilustrováno v diagramu 13.




Obrázek 13: Sekvenční diagram komunikace se serverem

Jakmile klient dostane všechny hodnoty zpět provede na populaci algoritmus NEAT (mutace, křížení, ...) a poté je nová generace poslána znovu na vyhodnocení.

Databáze

Všechny verze serverové části zaznamenávají průběh algoritmu NEAT do databáze, jejíž schéma lze vidět v obrázku 14. Databáze obsahuje tabulku **Genomes**, která uchová fitness nejlepšího a nejhoršího jedince v generaci, zároveň také obsahuje nejlepší genom z dané generace. Každý záznam v tabulce **Genomes** má přidělenou konfiguraci se kterou byl spuštěn. Toto je důležité při vyhodnocování více konfigurací zároveň, které je popsáno níže.



Obrázek 14: Schéma databáze

6.4 Návrh experimentů a simulačního prostředí

Experiment se bude skládat z agenta - vozidla, který bude vložen do simulovaného prostředí (sekce 7.1). Agent bude řízen neuronovou sítí (více v sekci 6.4).

Simulační prostředí

Návrh simulačního prostředí je nesmírně důležitý, protože definuje překážky, které musí agent překonat. Právě s pomocí simulačního prostředí lze postupně měnit obtížnost, jak je to stanoveno v zadání diplomové práce.

Po zvážení různých způsobů implementace simulačního prostředí bylo rozhodnuto, že se návrh vydá cestou procedurálního generátoru map. Ten bude fungovat tak, že se nejdříve nadefinují dílky prostředí ve kterých se bude agent pohybovat. Definice bude obsahovat dvě zásadní informace a o to prostředí, které dílek reprezentuje, což jsou informace o vozovce, dynamické prvky jako jsou třeba další auta, semafory a jiné. Zároveň bude obsahovat i informaci o tom na které další dílky navazuje (například silnice ve tvaru I může ze shora navazovat na sebe a na odbočku veleva). Procedurální generátor pak agenta vloží do specifikovaného dílku a při překročení stanovených hranic dílku (například pokud agent vyjede z obrazovky), dílek náhodně zamění za jiný navazující a agenta přesune na příslušnou pozici.

Tento přístup má následující výhody:

- Nízká paměťová náročnost. Stačí si uchovávat jen definice dílků
- Možnost generování rozmanitých testovacích prostředí
- Nízké nároky na síťový přenos - Není třeba přenášet mapu při změně konfigurace

Agent

Definice agenta zásadně ovlivňuje výsledek simulace, protože stanovuje vstupy a výstupy do a z neuronové sítě. V této práci bude testováno několik konfigurací, jejichž popis lze nalézt v této sekci a v sekci 6.4.

V případě této práce je agentem auto, které je vybaveno vzdálenostními senzory. Měření těchto senzorů je normalizováno (maximální vzdálenost měřícího paprsku je 800 m) a předáno jako vstup do neuronové sítě.

Řízení agenta bude probíhat tak, že se každý snímek s pomocí neuronové sítě na obrázku 16 rozhoduje, jakou akci podnikne. Má následující možnosti:


1. Ovládání volantu

- a) z_1 Otočení volantem o určitý počet stupňů doleva
- b) z_2 Otočení volantem o určitý počet stupňů doprava


2. Rychlostní stupně

- a) z_3 - zpátečka
- b) z_4 - rychlost

Ovládání volantu i volba rychlostního stupně probíhá zároveň a to tak, že se vždy z dané skupiny neuronů vybere ten, který má největší hodnotu. Tento přístup je identický tomu, který se používá například u neuronových sítí pro klasifikaci.



Obrázek 15: Řízení agenta



Obrázek 16: Neuronová síť agenta

Možné konfigurace agenta

Výše uvedenou konfiguraci lze rozšířit o níže uvedené vstupy/výstupy.

Modifikace vstupů umožní agentovi vnímat více než jen vzdálenosti z jednotlivých senzorů. Bude zajímavé pozorovat, jak se agent s jednotlivými vjemy poradí. V práci se vyzkouší následující přidané vstupy:

- aktuální rychlost
- náklon volantu

Modifikovat lze také výstupy neuronové sítě toto rozšíří nebo omezí možnosti agenta:

- Přidáním/odebráním možnosti udržení volantu ve stejné pozici

Fitness funkce

I přesto, že návrh fitness funkce spíše iterativní proces, který lze provést až po implementaci simulačního prostředí, lze si několik pravidel odvodit již v návrhu.

Je zřejmé, že bude třeba agenta nějakým způsobem penalizovat za nevhodné chování, jako je například kolize s překážkou. Možností penalizace agenta je hodně. Může to být buď předčasné přerušení simulace, které znemožní agentovi získat větší hodnotu fitness nebo to také může nabírat podoby odečtení určitého množství bodů z fitness skóre agenta.

Míra a podoba penalizace závisí na odzkoušeném chování agenta, který se může v rámci maximalizace fitness funkce chovat nepředvídatelně a bude jej tedy možné určit, až po implementaci práce. Pro ilustraci nepředvídatelných akcí si můžeme například představit agenta auto, které se díky špatně nastavené fitness funkci rozhodne jezdit po chodníku jenom proto, že penalizace srážky chodce je menší, než penalizace za kolizi s vozidlem.

Dalším faktorem, který musí být do fitness funkce zahrnut je motivace agenta. Na ní totiž ve velké míře závisí jeho výsledky. Může to být například požadavek na maximalizaci rychlosti agenta nebo můžeme například brát ohled na ujetou vzdálenost.

7 Implementace

Vlastní práce se skládá ze dvou částí. Klientská část, která slouží k vizualizaci algoritmu a zobrazení výsledků ze serverové části. Serverová část pro maximální urychlení simulace.

7.1 Simulace

Simulace je realizovaná jako knihovna pro Node.js, lze jí tedy použít jak u klientské části, tak u serverové části. Poskytuje kompletní fyzikální simulaci agenta, prostředí ve kterém se pohybuje, jeho ovládání a výpočet fitness funkce. Součástí simulačního prostředí je také kód pro její vizualizaci.

Rychlost byla zajištěna implementací profilovacího programu (**benchmark.js** ve složce `simulation`), který spouští simulaci na předem připravené populaci jedinců. Výstupem je pak doba, za jakou jí vyhodnotil na jednom jádře procesoru. Tento údaj byl pak používán při implementaci simulace pro orientační představu, jak moc případné změny v kódu ovlivňují rychlost samotné simulace. Dále byla simulace podrobena občasnému profilování v klientské části pomocí vývojářských nástrojů prohlížeče chrome, na kterém simulace jede nejlépe.

Nenáročnost, která souvisí s rychlostí, pak byla zajištěna tím, že bylo v průběhu psaní kódu dbáno na to, aby v průběhu simulace nedocházelo k přebytným alokacím, které by nejen mohly způsobit přebytný nárůst požadované paměti, ale hrozilo by také nepředvídatelné zpomalení, které sebou přináší jazyk využívající garbage kolektor.

Robustnost je podrobněji vysvětlená v sekci 7.1 a popis toho, jak bylo dosaženo stejných podmínek pro všechny agenty lze nalézt v návrhu 6.1 především v popisu RoadManageru.

Fitness funkce

Fitness funkce je důležitou součástí simulace, která zásadně ovlivňuje chování výsledných agentů a je tedy nutné jí volit vhodně. Je nutné, aby funkce agenta motivovala ke správné činnosti.

Po několika pokusech a konzultaci s vedoucím práce byla jako metrika úspěchu agenta zvolena celková vzdálenost, kterou je agent schopný překonat v průběhu jedné generace. Výpočet je realizován pomocí RoadDirectoru, který si při každém přechodu zaznamená bod, ve kterém se po přesunu agent nachází. Výsledná fitness je pak součet ураžených vzdáleností pro každou místnost. Road direktor si pro každou obrazovku uchovává vzdálenost, kterou agent v dané obrazovce překonal. Výsledným fitness je pak součet všech vzdáleností na všech obrazovkách.

Simulace může být také předčasně zastavena v případě, že agent koliduje s překážkou. Znemožní se mu tím získání většího skóre.


Simulační prostředí

Simulační prostředí poskytuje sadu překážek, kterou agent musí překonat. Testuje se tak, co je vlastně agent schopný se naučit. V zadání práce lze nalézt podmínku pro postupné stupňování obtížnosti, tohoto je dosaženo právě změnou simulovaného prostředí. V rámci těchto požadavků byly do road direktoru na-implementovány následující dílky.

Z obrázku 24 a tabulky 2 lze vyčíst, že vyhodnocení 1000 jedinců o 1000 generacích trvá něco okolo 9 h čistého výpočetního času a to do měření není započítáno to, že se agenti postupně zlepšují, což koreluje s delší dobou evaluace.


Z tohoto důvodu bylo ověřování rozděleno do 3 částí různých obtížností. Volba obtížnosti pak probíhá volbou vhodného dílků (prostředí), který má nastavené patřičné návaznosti. Protože se dílek I objevuje v simulačním prostředí dvakrát je pro jednoduchost duplikován a jsou mu změněny patřičné navazující dílky dle obtížnosti.

První konfigurace probíhá tak, že je agent postaven doprostřed silnice ve tvaru I (obrázek 17). Cílem je zjistit, zda agent je schopný naučit se jezdit (nebo alespoň couvat) rovně. V této konfiguraci je jedinou návazností (z obou možných směrů) samotný dílek I. Vzniká tak nekonečný tunel, kterým může agent cestovat.




Obrázek 17: Silnice ve tvaru písmene I

Další stupeň testuje schopnosti agenta vyhýbat se překážkám. Agent je opět postaven do silnice ve tvaru I, ale tentokrát jsou v ní zdi, kterým se musí vyhnout (obrázek 18). Návaznost z obou stran je opět samotný dílek (je to obdobně jako je tomu v první konfiguraci).




Obrázek 18: Silnice ve tvaru I s překážkami

Poslední Konfigurace se skládá z více dílků a testuje, zda a jak moc je schopný se agent naučit otáčet. K tomuto mu slouží malá dráha ve tvaru O skládající se z níže zobrazených dílků. Agent stejně jako v prvním případě začíná v silnici ve tvaru I s tím, že zde probíhá výše zmíněná změna návazností a to při průjezdu horní částí obrazovky je zaměněn na obrázek 19. V případě, že se agent vydá dolu je přesměrován na silnici ve tvaru L je tak nucen po zvládnutí jízdy dopředu naučit se zatáčet.




Obrázek 19: Silnice ve tvaru horizontálně obráceného L




Obrázek 20: Silnice ve tvaru L

V případě, že agent odbočí doprava je přesměrován na níže uvedený dílek ve tvaru -. Toto ověří, zda se agent dokáže přeorientovat na horizontální pohyb.




Obrázek 21: Silnice ve tvaru -

Po projetí dílku ve tvaru I je přesměrován na jeden z následujících dílků.



Obrázek 22: Silnice ve tvaru zrcadlově obráceného L



Obrázek 23: Horizontálně a vertikálně obrácené L

7.2 Serverová část

Jak je již zmíněno v návrhu serverová část vyhodnocuje jednotlivé jedince distribuovaně s pomocí fronty úkolů. Frontu poskytuje knihovna **Bull**, která používá **Redis** pro správu údajů o jednotlivých úkolech.

Cílem byla implementace robustního systému, který v ideálním případě rozloží výpočetní zátěž mezi jednotlivé uzly rovnoměrně. Dalším požadavkem byla možnost odpojení kdykoliv kteréhokoliv z počítačů, jelikož ne všechny počítače je možné mít puštěné po celou dobu vyhodnocování. Samotná implementace je dle návrhu rozdělena do dvou částí a to klientské části (implementace ve složce client), která obaluje algoritmus NEAT a posílá genomy na serverovou část. Serverová část obaluje simulaci a vyhodnocuje genomy na základě jejich konfigurace.

Konfigurovatelnost

Experimenty, které bude klientská část provádět jsou nastavitelné s pomocí dvou konfiguračních souborů. Globální konfigurační soubor *config.env*, který nastavuje proměnné prostředí umožňuje nastavit jedinou proměnnou a to FPS, která řídí jednotný krok simulačního enginu. Fixní krok je tu proto, aby se zajistilo, že všechny simulace běžely ve stejných podmínkách.

Druhým již zajímavějším konfiguračním souborem je *batch.json*. Tento soubor obsahuje informace o všech experimentech, které se mají spustit. Data o každém experimentu jsou uchována v jednoduchém JSON objektu, který obsahuje následující informace:

- Nastavení knihovny Neataptic:
 - INPUTS - Počet neuronů ve vstupní vrstvě ,
 - OUTPUTS - Počet neuronů ve výstupní vrstvě
 - POPSIZE - Velikost populace

- MUTATION_RATE - Pravděpodobnost mutace
- ELITISM - Zkopíruje beze změny N nejlepších jedinců
- EQUAL - Při zapnutí vede k větší diverzitě s ohledem na architekturu výsledných neuronových sítí
- Nastavení simulace
 - STARTING_PIECE - Dílek na kterém agent začíná. Jejích popis lze nalézt v RoadManageru
 - OPTIONS - Umožňuje zapnout některé z rozšíření (popsaných v kapitole 6.4). Následující možnosti
 - * holdWheel - Možnost držení volantu ve fixní pozici
 - * inputVelocity - Přidává na vstup neuronové sítě aktuální rychlost
 - * inputWheel - Přidává na vstup neuronové sítě aktuální náklon volantu
 - TIME - Počet vteřin, který určuje maximální dobu simulace

Výpočetní cluster

Ukázalo se, že vyhodnocování simulace zabírá neúměrné množství času a to i na nejvýkonnějším dostupném počítači.

Například vyhodnocení jedné generace populace o 1024 jedincích zabralo 60 s na nejsilnějším dostupném pc. Z tohoto důvodu bylo rozhodnuto o distribuci výpočetní zátěže mezi více počítačů. Byl vytvořen výpočetní cluster se specifikací popsanou v tabulce 1.

Procesor	RAM	Počet	Architektura
S5P6818 Octa core	1 GB	2	arm64
Broadcom BCM2837B0 quad-core	1 GB	1	arm32
Phenom X4 965	8 GB	1	x64
Intel Core i5-2300	4 GB	1	x64
Intel atom x5-Z8350	2 GB	1	x64
Cortex-A5	1 GB	1	armv7l

Tabulka 1: Použitý hardware

Lze i namítnout, že se zde projevuje určitá rezie při síťové komunikaci se serverem, což může být zdrojem určitého zpomalení.

Pro ověření rychlosti bylo provedeno měření výkonu clusteru a jeho porovnání s nejvýkonnější dostupnou sestavou. Měření bylo provedeno nad náhodně vygenerovanými populacemi. Jelikož se simulace může ukončit předčasně (například při kolizi s překážkou), byla simulace provedena pro každou velikost $10\times$ a výsledek byl

zprůměrován. Naměřená data lze nalézt v tabulce 2 ze které vychází obrázek 24 na kterém lze vidět výsledky tohoto srovnání.

Porovnání rychlosti clusteru s nejvýkonnějším dostupným počítačem ukazuje, že cluster je ve většině případů skoro stejně nebo výrazně rychlejší než samostatný výpočet. Jediné dvě naměřené instance, kde toto neplatí, je u populací o velikosti 100 a 200, kde si cluster vede mírně hůře, než nejvýkonnější dostupná sestava.


Toto lze vysvětlit jak přítomností méně výkonného hardwaru v clusteru (především se jedná o S5P6818) na které se musí u menších populací čekat. Pro ověření této teorie byl cluster spuštěn v dalších konfiguracích, kde byly postupně odebírány jednotlivé počítače a měření bylo opakováno.

- Cluster - Celý cluster
- Cluster-2 - Odebrán S5P6818 (obě jednotky)
- Cluster-3 - Odebrán Intel atom x5-Z8350
- Cluster-4 - Odebrán AMD A4-4300M

Jedinců	Cluster	Cluster-2	Cluster-3	Cluster-4	Phenom II X4 965
100	9.853	6.1684	3.6887	3.7583	6.5186
200	13.3993	9.126	6.451	7.1599	10.9839
300	15.5628	10.5351	9.08	10.8206	16.8723
400	17.7699	13.6263	11.9285	13.0231	23.5019
500	19.1542	14.303	15.349	16.3707	31.7831
600	20.4675	18.8677	18.571	20.0113	37.3242
700	23.4671	20.1617	20.9039	23.7305	40.66
800	25.07	23.3143	24.9978	26.3178	44.8019
900	29.3611	28.1234	26.6288	29.6816	52.8829
1000	30.5498	28.7635	29.5586	33.5195	62.8967
1100	32.2825	32.0137	30.7372	37.2753	65.2363
1200	34.3818	31.8152	34.0371	42.1325	72.2926
1300	37.3422	35.8219	37.4416	40.3347	75.2937
1400	38.4452	41.3896	38.6274	41.3493	81.1193
1500	40.0487	43.225	43.4606	43.9233	81.3101

Tabulka 2: Naměřená data

Je nutné však podotknout, že proměnlivá doba u vyhodnocování jedince znamená, že měření není zcela přesné. Nicméně lze na základě dat usoudit, že u větších populací dochází k přibližně 2× zrychlení.




Obrázek 24: Porovnání rychlosti clusteru s jedním PC

Docker swarm

Pro snadnou distribuci a správu byly všechny počítače zorganizovány do docker swarmu. Docker swarm obsahoval jednoho manažera (Broadcom BCM2837B0 quad-core), který zároveň spouštěl klientskou aplikaci a další služby:

Na manažeru nebyl spuštěn zpracovatel, aby se zabránilo jeho přetížení (manažer swarmu by měl být vždy dostupný).

Použití docker swarmu umožňuje především snadné nasazení a správu zpracovávajících procesů. Zároveň zajišťuje, že všechny instance zpracovatelů mají unifikovanou konfiguraci, což je zvláště důležité pro dosažení konzistentních výsledků.



Obrázek 25: Schéma distribuovaných výpočtů

Tento přístup má několik výhod a to:

1. Robustnost - Pokud jeden nebo více zpracovatelů selže (je například odpojen ze sítě) je možné pokračovat ve vyhodnocování (neúspěšný úkol lze vrátit zpátky

do fronty). Toto v kombinaci s výše zmíněným docker swarmem znamená, že jakýkoliv výpočetní uzel lze kdykoliv vypnout a po znovu zapojení do sítě si načte nejnovější konfiguraci a začne znovu vyhodnocovat bez potřeby jakékoliv manipulace s jakoukoliv částí swarmu.

2. Dobré rozložení zátěže - Jelikož si zpracovatel vytahuje úkoly z fronty, je vždy optimálně zatížen, a není třeba řešit rozložení mezi různě výkonnými a zatíženými počítači.
3. Škálovatelnost - problém lze škálovat až do doby, kdy počet procesorů nepřesáhne počet potřebných simulací. Chceme-li tedy vypočítat generaci o tisíci jedincích můžeme na ně nasadit až tisíce procesorů.

Problémy implementace

Při implementaci serverové části a přehrávače byl objeven zásadní problém. Při vložení výsledného genomu do přehrávače se v některých případech rozcházela výsledná fitness agenta s fitness, která byla naměřena v přehrávači.

Tuto odchylku lze vysvětlit nevyhnutelnou přítomností výpočtů, které potřebují čísla s plovoucí desetinnou čárkou, kterou vyžaduje hlavně použitý fyzikální engine a výpočty, které probíhají při vyhodnocování výstupů z neuronové sítě a to z několika důvodů:

Ačkoliv je standard IEEE-754 deterministický nezaručuje stejný výsledek na rozdílném HW a už vůbec ne na HW v rozdílných architekturách. Problém může například nastat u volby zaokrouhlovacího módu, kterých standard IEEE-754 definuje několik a které mírně ovlivňují výslednou hodnotu.

Standard JavaScriptu nespecifikuje přesnou implementaci trigonometrických funkcí, které se hojně používají u vektorové algebry, která se opět využívá hlavně u výpočtů fyzikálního enginu.

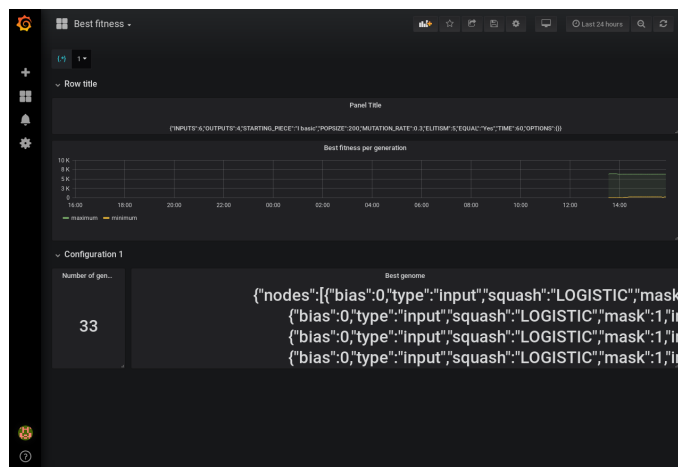
I přes to, že odchylky způsobené výše uvedenými jevy jsou relativně malé je třeba myslet na to, že se akumulují s časem a také na to, že řídicí neuronová síť se může za velmi obdobných podmínek zachovat diametrálně odlišně.

Monitorování stavu

Pro monitorování stavu algoritmu byla použita webová aplikace Grafana. Jak již bylo řečeno v sekci 3.5 jedná se o nástroj pro snadnou vizualizaci dat v databázi. V případě této práce posloužila k vytvoření jednoduchého kontrolního panelu, který obsahoval následující informace:

- Graf zobrazující fitness nejlepšího/nejhoršího jedince dle generací
- Textové pole, které obsahuje nejlepší genom
- Numerické pole, které obsahuje počet generací

- Textové pole s konfigurací v jsonu



Obrázek 26: Kontrolní panel v aplikaci grafana

Serverová část má možnost vyhodnocovat více konfigurací zároveň, toto je reflektováno v návrhu kontrolního panelu, který umožňuje nejen zobrazovat a porovnávat jednotlivé konfigurace ale také dle nich filtrovat. Toto probíhá s pomocí menu v levém horním rohu.

7.3 Uživatelská část

Uživatelská část byla navržena tak, aby byla schopná vizualizovat průběh algoritmu NEAT a zároveň měla možnost znovu vyhodnocení existujících genomů vygenerovaných serverovou částí. První požadavek vznikl na základě konzultace s vedoucím, který chtěl algoritmus NEAT demonstrovat v hodinách předmětu VUI2. Druhý požadavek vznikl z důvodu potřeby vizualizace řešení, které generoval sever.


Klientská část je implementovaná jako **VUE.js** aplikace realizovaná s pomocí 3 rozdílných komponent. Kromě uvedených obrazovek se jedná o komponentu *Simulation*, která obaluje samotnou simulaci a vykreslování agenta. Používá jí jak přehrávač, tak vizualizace v reálném čase.

Vizualizace

Vizualizace se skládá z jednoduchého rozhraní, které lze vidět na obrázku 27. V horní části je graf, zobrazující průběh genetického algoritmu. Lze v něm nalézt fitness nejlepšího, nejhoršího a průměrného jedince v populaci.

Další část se skládá z konfigurovatelného množství simulačních prostředí. Jednotliví jedinci v generaci jsou pak rovnoměrně rozloženi mezi všechna simulační prostředí a uživatel může pozorovat vývoj jedinců v reálném čase.

Poslední tlačítko slouží k urychlení simulace. Způsobí to, že se simulace začne obnovovat bez vykreslování. Toto jí značně zrychlí.

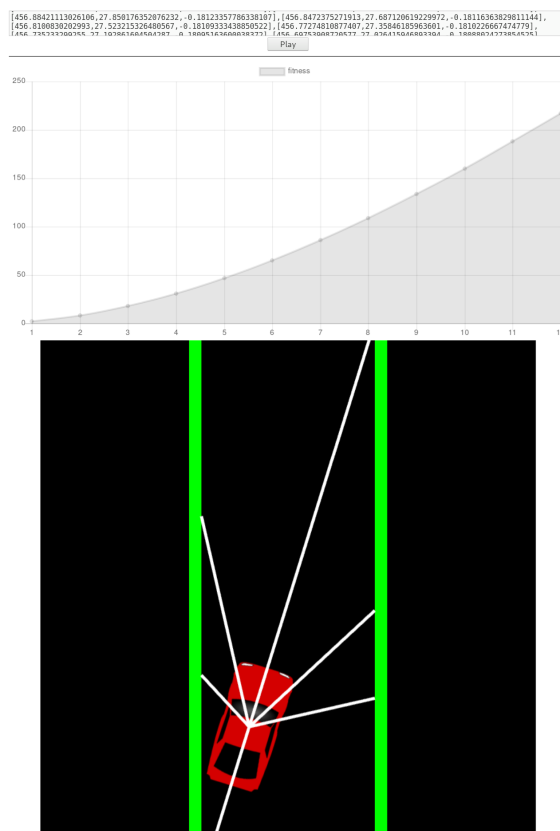


Obrázek 27: Uživatelské rozhraní klientské části

Přehrávač

Přehrávač genomů také poskytuje jednoduché rozhraní skládající se z textové části pro vložení genomu (výstup ze serverové části lze zobrazit například v grafaně), graf pro zobrazení průběhu fitness agenta a vykreslovací část, která zobrazuje, jak si agent vedl. Pro menší výpočetní nároky je do grafu zapisována fitness každou vteřinu. Výsledná komponenta se nachází na obrázku 28.

Díky problémům s implementací naznačených v sekci 7.2 bylo třeba vymyslet alternativní způsob přehrávání. Nakonec byl návrh pozměněn tak, že si serverová část ukládá pro každý snímek pozice, úhel, aktuální fitness a dílek na kterém se agent nachází, kterou pak přehrávač interpretuje oproti klasickému přístupu, který by zahrnoval opětovnou simulaci agenta se stejným genomem. Tímto je dosaženo toho, že si lze zobrazit průběh agenta tak, jak tomu bylo při jeho vyhodnocování.



Obrázek 28: Rozhraní přehravače

7.4 Nasazení serverové části

Jak již bylo zmíněno serverová část je obalená do docker kontejneru jednak pro snadné nasazení a jednak z důvodu zahrnutí do swarmu.

Nejdříve je potřeba vytvořit swarm. Tohoto lze dosáhnout zadáním příkazu *docker swarm init* na počítači, který chceme používat jako swarm manager (lze také použít *docker-machines* a výpočty dělat na jednom počítači). Po jeho zadání se vytvoří docker swarm a zároveň je vypsán příkaz, který lze použít pro připojení dalších uzlů do swarmu (lze ho zobrazit i později s použitím příkazu *docker swarm join-token worker*).

Nasazení probíhá nejdříve spuštěním příkazu *docker-compose up* ve složce **client**. Toto kromě samotného klienta spustí jak následující služby:

- Databáze
 - Redis - pro **Bull**
 - Postgresql - pro ukládání informací o průběhu algoritmu

- Služby pro monitorování
 - Grafana (port 3000) - pro monitorování stavu algoritmu NEAT
 - Arena (port 4567) - pro monitorování stavu **Bull**
 - Portainer (port 9000) - pro monitorování swarmu
 - Adminer (port 8080) - pro správu databáze

Po úspěšném provedení tohoto příkazu je třeba spustit zpracovatele na jednotlivých uzlech swarmu. Lze toho dosáhnout přechodem do složky **Server** a spuštěním příkazu `docker deploy Server --compose-file docker-compose.yml`. Protože je tento příkaz v době psaní práce označen jako experimentální je třeba ho povolit. Tohoto je dosaženo modifikací souboru **daemon.json** (na linuxu je ho nutné vytvořit v `/etc/docker/daemon.json`) přidáním řádku `"experimental": true`.

Po tomto kroku je třeba ještě nastavit správnou ip adresu a port **Redis** serveru (ip adresa swarm mangeru) v souboru `config.env`.

Po provedení těchto kroků je na každém uzlu spuštěn vyhodnocovatel, který začne automaticky stahovat a vyhodnocovat jednotlivé jedince. V případě vypnutí/pádu uzlu je úkol po čase vrácen do fronty a vyhodnocení probíhá na jiném uzlu.

Grafana

Grafana vyžaduje další nastavení v podobě naimportování použitého kontrolního panelu a nastavení databázového zdroje.

Exportovaný kontrolní panel, který je k nalezení v příloze diplomové práce lze naimportovat z menu *Dashboards->manage*, které se nachází v levém kontrolním panelu.

Přihlašovací údaje do PostgreSQL serveru jsou k nalezení také v příloze.

7.5 Nasazení uživatelské části

Uživatelskou část lze jednoduše nasadit s pomocí manageru závislostí *npm*. Stačí ve složce s implementací spustit příkaz (po nainstalování závislostí) `npm run dev` a pak si v prohlížeči otevřít adresu `localhost:8080`. V případě přehrávače je to `localhost:8080/#/player`

8 Experimenty

Po návrhu simulačního prostředí byl agent vyzkoušen v několika situacích se stupňující se obtížností. Každá simulace probíhala se 100 jedinci do té doby než se fitness funkce u všech stabilizovala po dostatečně dlouhou dobu. Toto trvalo 400 generací a přibližně 20 hodin čistého výpočetního času. Doba vyhodnocování byla nastavena na 120 vteřin. Volba ostatních hyper-parametru proběhla na základě empirických zkušeností získaných v průběhu implementace.

Ačkoliv je pravděpodobné, že by delší doba evaluace by pravděpodobně vyústila v lepší výsledky její výpočet v různých konfiguracích se ukázal jako příliš časově náročný, navíc empirické pozorování ukázalo, že tato konfigurace poskytuje dostatečně dobré výsledky za snesitelný čas.

S ohledem na časovou náročnost výpočtů byly zkoušeny jen konfigurace popsané v návrhu (sekce 6.4) na implementovaných dílcích k náhledu v sekci 7.1.


V rámci časové úspory je každý stupeň testován jen 2x. První pokus probíhá jakýchkoliv rozšíření (vstupů/výstupů) a poté zopakován se všemi dostupnými. Cílem je zjistit, jak moc tato rozšíření ovlivňují výsledného agenta.

8.1 První stupeň - silnice ve tvaru I

Silnice ve tvaru I byla v obou případech agentem úspěšně překonána. Je zajímavé, že ačkoliv byl výsledný pohyb agenta stejný (relativně rovná jízda dozadu) jsou zde odlišnosti ve výsledných neuronových sítích agenta v obou konfiguracích.


Konfigurace bez rozšíření

Konfigurace bez rozšíření vygenerovala agenta, který jede dozadu a reguluje směr jízdy mírným kývavým pohybem. Z průběhu fitness funkce je vidět, že agent dosáhl dobrých výsledků již v druhé generaci. Další generace přibývaly výsledné neuronové sítě na komplexnosti bez větší změny v chování agenta a fitness.



Obrázek 29: Průběh evaluace - I bez rozšíření


Na výsledné neuronové síti je zajímavá zpětná vazba u prostředního oranžového neuronu s aktivační funkcí tanh, která se pravděpodobně stará o onen kývavý pohyb.



Obrázek 30: Neuronová síť - I bez rozšíření


Konfigurace s rozšířeními

Konfigurace s rozšířením byla i díky možnosti držení volantu ve fixní poloze schopná okamžitě najít možné řešení.



Obrázek 31: Průběh evaluace - I s rozšířeními

Ve finální verzi přidala neurony do skryté vrstvy. Není jisté, zda jsou vůbec k něčemu dobré, protože pro řešení této úlohy stačí v dané konfiguraci pouze přidat plyn dozadu/dopředu a držet volant.



Obrázek 32: Neuronová síť - I s rozšířeními

8.2 Druhý stupeň - silnice ve tvaru I s překážkami

Druhý stupeň obtížnosti už dělal agentovi větší problém a nepodařilo se za daný časový limit vyvinout agenta, který by ho překonal bez kolize. V tomto stupni je také vidět velký rozdíl mezi konfigurací s rozšířeními a bez rozšíření. Konfigurace s rozšířeními si totiž vedla značně lépe.


Konfigurace bez rozšíření

Na první obrazovce si agent vedl docela dobře. Překážky obešel obdobným kývavým pohybem, jako je tomu u první verze, nicméně po přechodu na další obrazovku neuspěl a narazil do zdi.



Obrázek 33: Graf průběhu fitness - bez překážek


Na výsledné neuronové síti je zajímavá přítomnost neuronu s aktivační funkcí absolutní hodnota, který by mohl hrát roli právě ve vyhýbání se překážkám. Mohl by totiž sloužit jako přepínač pro zatačení.



Obrázek 34: Neuronová síť - silnice ve tvaru I s překážkami bez rozšíření

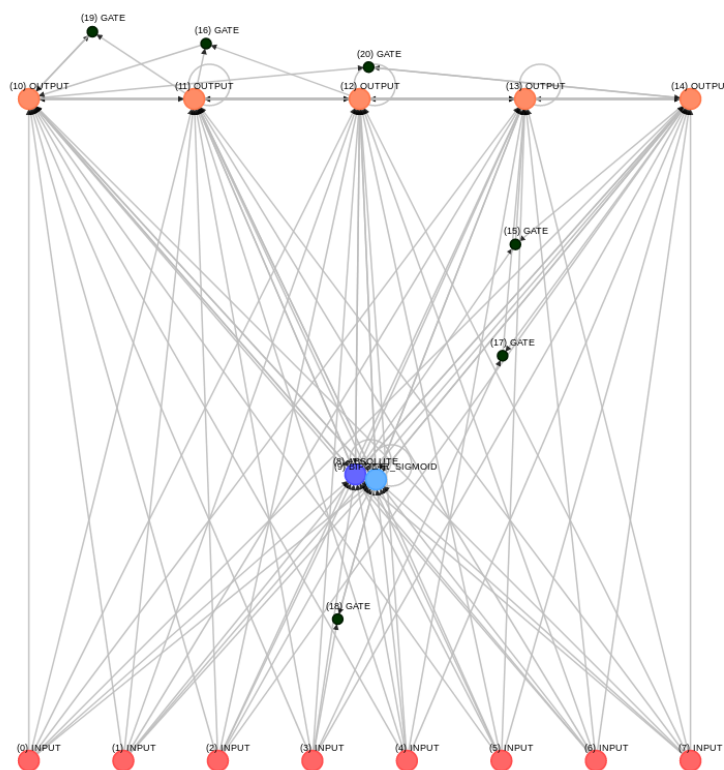
Konfigurace s rozšířeními

Konfigurace s rozšířením byla schopná překonat větší část druhé obrazovky a dosáhnout přibližně dvojnásobku fitness konfigurace bez rozšíření.



Obrázek 35: Graf průběhu fitness funkce - s překážkami

Na výsledné neuronové síti je vidět, že je mnohem komplexnější než kterákoliv předchozí. Je opravdu těžké určit účel jednotlivých neuronů. Zajímavé je, že obsahuje jak neuron s aktivační funkcí absolutní hodnoty, jako je tomu v konfiguraci bez rozšíření, tak neuron s aktivační funkcí sigmoid, která může sloužit k dorovnání směru například na základě vstupní rychlosti.



Obrázek 36: Neuronová síť - silnice ve tvaru I s překážkami s rozšířeními

8.3 Třetí stupeň - Okruh

Stejně jako je tomu u předchozího případu se ani jedné konfiguraci nepovedlo překonat simulační prostředí bez kolize s překážkou.

Konfigurace bez rozšíření

V základní konfiguraci agent dorazil do vrchní části mapy (dílek ve tvaru obráceného L), kde narazil při pokusu o vytočení překážky.




Obrázek 37: Průběh fitness - Okruh bez rozšíření


Překvapující je, že toto dokázal bez jakýchkoliv přídavných neuronů.

Konfigurace s rozšířením

Agent si nejprve nacouval do spodní části obrazovky a pak se pokusil pod úhlem překonat vrchní část mapy. Dostal se trochu dál než agent bez rozšíření ale také kolidoval s překážkou.




Obrázek 38: Neuronová síť - Okruh bez rozšíření



Obrázek 39: Průběh fitness funkce - Okruh bez rozšíření

Ve výsledné neuronové síti se nachází neuron s aktivační funkcí SELU. SELU je variace RELU, která by v této konfiguraci mohla sloužit jako implementace výše popsaného manévru.



Obrázek 40: Neuronová síť - Okruh s rozšířením

8.4 Zhodnocení

Ačkoliv se výsledným agentům podařilo úspěšně zdolat pouze první překážku, je na provedených experimentech a jejich výsledcích vidět, že lze neuroevoluci použít i pro obtížnější terén. Jediným limitem je časová, případně HW náročnost experimentu.

Experiment odhalil, že algoritmus NEAT ve verzi instinct je schopný produkovat jedince, kteří jsou schopní i komplexních akcí (například manévr popsany u třetího stupně) a to za použití neuronových sítí, jejichž architektura je relativně jednoduchá.

Bylo také zjištěno, že navrhovaná rozšíření značně zlepšují fitness zkoumaného agenta oproti verzi bez rozšíření. Toto lze připsat nejen více dostupným informacím ale hlavně větší kontrole nad vozidlem, které neuronové sítě nabízí možnost držení volantu ve stejném směru.

Je pravděpodobné, že při dostatečném množství času nebo výpočetního výkonu by bylo možné překonat nejen překážky, které jsou implementovány v této práci ale i překážky, které jsou mnohem složitější. Práce tímto otevírá možnosti na další, podrobnější testování, které se v ní z časových důvodů nepovedlo.

9 Možná vylepšení

Při implementaci aktuálního řešení bylo zjištěno, že řešený problém je mnohem výpočetně náročnější než se při původním návrhu čekalo. Toto vedlo k návrhu distribuovaného řešení, které ovšem sebou nese problémy v rozdílech u výpočtů s desetinou čárkou.

Z tohoto důvodu by experimentu prospělo použití homogenního clusteru. Předělo by se problémům, které sebou přináší gridový cluster.

Dalším možným rozšířením by bylo spuštění řešení na clusteru s větším výpočetním výkonem. Toto by umožnilo vyzkoušet více experimentů a konfigurací, což by vedlo k lepší představě o možnostech samotného algoritmu. Navíc by to umožnilo plně využít potenciál, který nabízí oddělený simulační kód (simulace s dynamickými prvky, ...).

Poslední možností by byla reimplementace existujícího řešení v některém ze systémových jazyků (**C**, **C++**, **Rust**). Došlo by tak k určitému zrychlení výpočtů a bylo by tedy možné vyhodnotit více jedinců na jednom počítači než doposud.

Grafickou část aplikace by bylo možné rozšířit o různá nastavení, která jsou v tuto chvíli dostupná jen ve zdrojovém kódu aplikace.

10 Závěr

Tato práce se zabývala návrhem a tvorbou prostředí pro simulovaného agenta i jeho řízení pomocí upraveného algoritmu neuroevoluce. Následoval návrh, provedení a zhodnocení experimentů, které byly navrženy tak, aby testovaly možnosti agenta.

Testování agenta proběhlo v různých obtížnostech za různých podmínek. Z provedených testů vyplývá obrovský potenciál metody neuroevoluce, která demonstrovala svojí schopnost řešení komplexních problémů, jako je řízení automobilu a to za použití neuronových sítí. Jejich složitost je oproti konkurenčním řešením, jako je například zpětnovazební učení velmi malá.

Nevýhodou této metody je ovšem její velká časová náročnost, která značně limitovala možnosti této práce a zpomalovala její vývoj.

I přes výše zmíněná omezení se v práci podařilo pomocí výpočetního clusteru vytvořit testovací systém, který je nejen robustní ale i snadno škálovatelný. Použitím většího výpočetního výkonu by tak bylo možné dosáhnout mnohem lepších výsledků a podívat se na limity zkoumané metody do větší hloubky. Bylo například možné plně využít potenciál navrženého řešení pro tvorbu prostředí s dynamickými prvky, jako jsou například další automobily nebo dopravní značení.

11 Literatura

- [BUDUMA, Nikhil 2017] BUDUMA, NIKHIL. *Fundamentals of deep learning: designing next-generation machine intelligence algorithms*. Sebastopol: O'Reilly, 2017. ISBN 978-149-1925-614..
- [HYNEK, Josef., 2008] HYNEK, JOSEF. *Genetické algoritmy a genetické programování*. Praha: Grada, 2008. Průvodce (Grada). ISBN 978-80-247-2695-3..
- [KOZA, JOHN R., 1992] KOZA, JOHN R. *Genetic programming: on the programming of computers by means of natural selection*. Cambridge, Mass.: MIT Press, c1992. ISBN 0-262-11170-5..
- [LÝSEK Jiří, ŠŤASTNÝ Jiří, 2014] LÝSEK, JIŘÍ a ŠŤASTNÝ, JIRI. (2014). *Automatic discovery of the regression model by the means of grammatical and differential evolution*. Agricultural Economics (AGRICECON). 60. 546-552. 10.17221/160/2014-AGRICECON. .
- [MACRAE, CALLUM., 2018] MACRAE, CALLUM. *Vue.js: up and running: building accessible and performant web apps*. Sebastopol, California: O'Reilly Media, [2018]. ISBN 1491997249..
- [MITCHELL, Melanie., 1996] MITCHELL, MELANIE. *An introduction to genetic algorithms*. Cambridge: Bradford Book, c1996. ISBN 0-262-13316-4..
- [MNIH, VOLODYMYR, KORAY KAVUKCUOGLU, DAVID SILVER, et al., 2015] MNIH, VOLODYMYR, KORAY KAVUKCUOGLU, DAVID SILVER, et al., *Human-level control through deep reinforcement learning*. Nature [online]. 2015, 518(7540), 529-533 [cit. 2019-01-01]. DOI: 10.1038/nature14236. ISSN 0028-0836. Dostupné z: <http://www.nature.com/articles/nature14236>.
- [PATTERSON, Josh. 2017] PATTERSON, JOSH. *Deep learning : a practitioner's approach Deep learning : a practitioner's approach. 1*. Beijing ; Boston ; Farnham ; Sebastopol ; Tokyo: O'Reilly, 2017. ISBN 978-1-491-91425-0..
- [P. MENEZES JR., JOSE A GUILHERME BARRETO. 2006] P. MENEZES JR., JOSE A GUILHERME BARRETO. *A New Look at Nonlinear Time Series Prediction with NARX Recurrent Neural Network*. In: 2006 Ninth Brazilian Symposium on Neural Networks (SBRN'06) [online]. IEEE, 2006, 2006, s. 28-28 [cit. 2019-01-02]. DOI: 10.1109/SBRN.2006.7. ISBN 0-7695-2680-2. Dostupné z: <http://ieeexplore.ieee.org/document/4026828/>.
- [PETROSKI SUCH, FELIPE a kol., 2018] PETROSKI SUCH, FELIPE, VASHISHT MADHAVAN, EDOARDO CONTI, JOEL LEHMAN, KENNETH O. STANLEY a JEFF CLUNE. *Deep Neuroevolution: Genetic Algorithms*

- Are a Competitive Alternative for Training Deep Neural Networks for Reinforcement Learning* [online]. [cit. 2019-01-01]. DOI: arXiv:1712.06567v1. Dostupné z: <https://arxiv.org/abs/1712.06567v1>.
- [RUSSELL, STUART J., PETER NORVIG a ERNEST DAVIS, 2010] RUSSELL, STUART J., PETER NORVIG a ERNEST DAVIS. *Artificial intelligence: a modern approach. 3rd ed.* Boston: Pearson, c2010. Prentice Hall series in artificial intelligence. ISBN 978-0-13-207148-2..
- [SILVA, FERNANDO, PAULO URBANO, LUÍS CORREIA a ANDERS L. CHRISTENSEN, 2015] SILVA, FERNANDO, PAULO URBANO, LUÍS CORREIA a ANDERS L. CHRISTENSEN. *OdNEAT: An Algorithm for Decentralised Online Evolution of Robotic Controllers.* Evolutionary Computation. 2015, 23(3), 421-449. DOI: 10.1162/EVCO_a_00141. ISSN 10636560. Dostupné také z: http://www.mitpressjournals.org/doi/10.1162/EVCO_a_00141.
- [STANLEY, Kenneth O, Risto MIIKKULAINEN., 2002] STANLEY, KENNETH O. a RISTO MIIKKULAINEN. *Evolving Neural Networks through Augmenting Topologies.* In: Evolutionary Computation [online]. 2002, 10(2), s. 99-127 [cit. 2018-12-08]. DOI: 10.1162/106365602320169811. ISSN 1063-6560. Dostupné z: <http://www.mitpressjournals.org/doi/10.1162/106365602320169811>.
- [STANLEY, KENNETH O., DAVID B. D'AMBROSIO a JASON GAUCI., 2009] STANLEY, KENNETH O., DAVID B. D'AMBROSIO a JASON GAUCI. *A Hypercube-Based Encoding for Evolving Large-Scale Neural Networks.* *Artificial Life* [online]. 2009, 15(2), 185-212 [cit. 2018-12-15]. DOI: 10.1162/artl.2009.15.2.15202. ISSN 1064-5462. Dostupné z: <http://www.mitpressjournals.org/doi/10.1162/artl.2009.15.2.15202>.
- [Vue.js, 2014] *Vue.js.* Vue.js [online]. Copyright © 2014 [cit. 01.01.2019]. Dostupné z: <https://vuejs.org/>.

Přílohy

A Přihlašovací údaje k PostgreSQL

Databáze PostgreSQL dostupná z docker kontejneru serverové části má následující přihlašovací údaje:

- Adresa - postgresql:5432
- Jméno - postgres
- Heslo - postgres

V grafaně je při zadávání přihlašovacích údajů vypnout SSL mod, jinak se nejde přihlásit.

B Obsah CD

Příložené CD obsahuje kromě zdrojových kódů všech částí, také výsledky experimentu.