

Mendelova univerzita v Brně  
Provozně ekonomická fakulta

---

# **Řízení autonomního agenta pomocí neuroevoluce**

**Diplomová práce**

Vedoucí práce:  
Ing. Jiří Lýsek, Ph.D.

Bc. Martin Hnátek

Brno, 2018

Rád bych zde poděkoval svému vedoucímu Ing. Jiří Lýskovi, Ph.D. za jeho rady a čas, který mi věnoval při řešení této práce.

### **Čestné prohlášení**

Prohlašuji, že jsem práci: **Řízení autonomního agenta pomocí neuroevoluce** vypracoval samostatně a veškeré použité prameny a informace uvádím v seznamu použité literatury. Souhlasím, aby moje práce byla zveřejněna v souladu s § 47b zákona č. 111/1998 Sb., o vysokých školách a o změně a doplnění dalších zákonů (zákon o vysokých školách), ve znění pozdějších předpisů, a v souladu s platnou *Směrnicí o zveřejňování vysokoškolských závěrečných prací*.

Jsem si vědom, že se na moji práci vztahuje zákon č. 121/2000 Sb., autorský zákon, a že Mendelova univerzita v Brně má právo na uzavření licenční smlouvy a užití této práce jako školního díla podle § 60 odst. 1 autorského zákona.

Dále se zavazuji, že před sepsáním licenční smlouvy o využití díla jinou osobou (subjektem) si vyžádám písemné stanovisko univerzity o tom, že předmětná licenční smlouva není v rozporu s oprávněnými zájmy univerzity, a zavazuji se uhradit případný příspěvek na úhradu nákladů spojených se vznikem díla, a to až do jejich skutečné výše.

V Brně dne 12. listopadu 2018

.....

**Abstract**

Autonomous agent control using neuroevolution

**Abstrakt**

Řízení autonomního agenta pomocí neuroevoluce

Tato práce se zabývá trénováním autonomního agenta - auta s pomocí algoritmu neuroevoluce. Toto zahrnuje tvorbu simulačního prostředí pro agenta, vhodným návrhem agenta (senzorů a řízení) a také návrhem fitness funkce

## Obsah

<b>1</b>	<b>Úvod a cíl práce</b>	<b>6</b>
1.1	Úvod do problematiky . . . . .	6
<b>2</b>	<b>Neuronové sítě</b>	<b>7</b>
2.1	Druhy úloh neuronových sítí . . . . .	7
2.2	Neuron . . . . .	7
	Aktivační funkce . . . . .	7
	Lineární funkce . . . . .	7
	Sigmoid . . . . .	8
	Tanh . . . . .	8
	RELU . . . . .	9
2.3	Genetické algoritmy . . . . .	9
	Princip . . . . .	10
	Kódování . . . . .	10
	Křížení . . . . .	10
	Mutace . . . . .	10
	Selekce . . . . .	11
2.4	Neuroevoluce . . . . .	11
<b>3</b>	<b>Použité technologie</b>	<b>12</b>
3.1	Docker . . . . .	12
3.2	Vue . . . . .	12
3.3	Node.js . . . . .	12
3.4	Traefik . . . . .	12
<b>4</b>	<b>Vlastní práce</b>	<b>13</b>
4.1	Simulace . . . . .	13
	Fitness funkce . . . . .	13
4.2	Serverová část . . . . .	13
4.3	Klientská část . . . . .	13
4.4	Simulace . . . . .	13
<b>5</b>	<b>Reference</b>	<b>14</b>
	<b>Přílohy</b>	<b>15</b>
<b>A</b>	<b>CD se zdrojovým kódem</b>	<b>16</b>

# 1 Úvod a cíl práce

## 1.1 Úvod do problematiky

S růstem výpočetního výkonu a rozvojem **gpugpu** (paralelizace výpočtů na grafické kartě) se neuronové sítě ukázaly jako mocný nástroj pro řešení složitých problémů na které standardní metody umělé inteligence nestačily. K dalším možnostem

## 2 Neuronové sítě

Neuronové sítě jsou model strojového učení, který je volně založený na principu zvířecího mozku. (PATTERSON, Josh. 2017, s. 41)

### 2.1 Druhy úloh neuronových sítí

Neuronové sítě se používají především pro řešení regresních a klasifikačních problémů.

### 2.2 Neuron

Neuron je základní jednotka neuronových sítí, která je definovaná jako suma všech jejích vstupů a aplikace aktivační funkce.

$$\sigma(\sum_{i=0}^N \theta \cdot x_i + b)$$


#### Aktivační funkce

Aktivační funkce se používá pro definování výstupu a zavedení nelinearity. Bez nich by byla neuronová síť schopna aproximovat pouze n-dimenzionální rovinu. (PATTERSON, Josh. 2017, s. 65)

Dalším využitím je omezení výstupních hodnot. Například aktivační funkce sigmoid se s oblibou používá u výstupní vrstvy neuronových sítí určených ke klasifikačním problémům, protože je to relace  $\mathbb{R} \rightarrow \{0..1\}$ , která se dá jednoduše jako "jistota" neuronu, že se jedná o výstup, který neuron reprezentuje. Podobně se dá uvažovat i o funkcích jako je například softmax a tanh, které také najdou hojné využití u klasifikačních problémů.

#### Lineární funkce


Vrací vstup, tak jak je. Využití najde především u vstupní vrstvy neuronové sítě a u neuronových sítí, které řeší regresní typy úloh.



$$f(x) = x$$

### Sigmoid

Sigmoid je aktivační funkce, která je schopná potlačit extrémní hodnoty




$$f(x) = \frac{1}{1 + e^{-x}}$$

### Tanh

Tanh je funkce obdobná sigmoidu. Hlavní rozdíl mezi ní a sigmoidem je ten, že její obor je v rozmezí -1 a 1 hodí se proto i pro záporná výstupy, které vyžadují záporná čísla. (PATTERSON, Josh. 2017, s. 67)






$$f(x) = \tanh(x)$$

## RELU

RELU je aktivační funkce, která je podobná lineární aktivační funkci s tím rozdílem, že pokud vstupní hodnota nepřesáhne určitého prahu výstupem je 0. Její hlavní výhodou je to, že zabraňuje problémům s takzvaným explodujícím gradientem (PATTERSON, Josh. 2017, s. 69)



$$f(x) = \begin{cases} x & x \geq 0, \\ 0 & x < 0, \end{cases}$$

## 2.3 Genetické algoritmy

Genetické algoritmy slouží k řízenému prohledávání stavového prostoru založené na teorii evoluce.

## Princip

Základní myšlenka spočívá ve vygenerování náhodných jedinců (řešení problému) a jejich postupné zlepšování s pomocí operací křížení a mutace. Proces zlepšování genomů probíhá na základě jeho hodnocení (fitness).

Samotný algoritmus pak lze rozdělit na následující kroky (MITCHELL, Melanie., 1996, s. 12)

1. Vygeneruj náhodnou populaci o  $n$  chromozomech
2. Pro každý chromozom spočítej jeho fitness
3. Opakuj  $n$  krát
  - a) Vyber pár chromozomů na základě jejich ohodnocení (selekce)
  - b) S určitou pravděpodobností  $p_c$  rozděl pár chromozomů na náhodném místě a jejich spojením.
  - c) S určitou pravděpodobností mutuj daného jedince
4. Nahraď současnou populaci populací, která vznikla předchozím krokem
5. Jdi na krok 2

## Kódování

Způsob zápisu řešení problému. Existuje mnoho různých kódování a každý má své výhody a nevýhody. Zde je seznam několika nepoužívanějších kódování (HYNEK, Josef., 2008, s. 42-43):

1. Binární - řetězec bitů, který může například reprezentovat jednu nebo více numerických hodnot.
2. Realná čísla - Jedno nebo více reálných čísel
3. Kombinatorické - Může být například seznam čísel označujících

## Křížení

Křížení je operátor, který kombinuje dva jedince do jednoho. Jeho implementace je samozřejmě závislá na

## Mutace

Mutace náhodně modifikuje chromozom a zavádí tak do populace variaci.

**Selekce**

Selekce je proces výběru dvou jedinců na něž jsou později aplikovány genetické operátory jako je křížení a mutace.

**2.4 Neuroevoluce**

## **3 Použité technologie**

### **3.1 Docker**

### **3.2 Vue**

### **3.3 Node.js**

### **3.4 Traefik**

## 4 Vlastní práce

Vlastní práce se skládá ze dvou částí: klientská část, která slouží k vizualizaci algoritmu a zobrazení výsledků ze serverové části. Serverová část pro maximální zrychlení simulace.

### 4.1 Simulace

#### Fitness funkce

Fitness funkce je důležitou součástí simulace, která zásadně ovlivňuje chování výsledných agentů.

### 4.2 Serverová část

Serverová část obaluje simulaci do jednoduchého REST api. V rámci co největší rychlosti byl vytvořen i jednoduchý klient, který provádí algoritmus NEAT a pro vyhodnocení jednotlivých jedinců využívá toto API. API má jen jeden endpoint a to `/evaluate`, který přebírá pole json objektů z nichž každý obsahuje informace o neuronové síti vygenerované s pomocí knihovny NEAT. Ačkoliv se může zdát, že tento přístup bude pomalejší díky přídavné režii, kterou s sebou nese síťová komunikace tento přístup má i své výhody. Hlavní výhodou je možnost rozložení samotných výpočtů mezi několik počítačů.

### 4.3 Klientská část

### 4.4 Simulace

## 5 Reference

- BUDUMA, Nikhil. *Fundamentals of deep learning: designing next-generation machine intelligence algorithms*. Sebastopol: O'Reilly, 2017. ISBN 978-149-1925-614..
- PATTERSON, Josh. *Deep learning : a practitioner's approach Deep learning : a practitioner's approach. 1.* Beijing ; Boston ; Farnham ; Sebastopol ; Tokyo: O'Reilly, 2017. ISBN 978-1-491-91425-0..
- MITCHELL, Melanie. *An introduction to genetic algorithms*. Cambridge: Bradford Book, c1996. ISBN 0-262-13316-4..
- HYNEK, Josef. *Genetické algoritmy a genetické programování*. Praha: Grada, 2008. Průvodce (Grada). ISBN 978-80-247-2695-3..

## **Přílohy**

## **A CD se zdrojovým kódem**