

# Řízení autonomního agenta pomocí neuroevoluce

Diplomová práce

Vedoucí práce:  
Ing. Jiří Lýsek, Ph.D.

Bc. Martin Hnátek

Brno, 2018

Rád bych zde poděkoval svému vedoucímu Ing. Jiří Lýskovi, Ph.D. za jeho rady a čas, který mi věnoval při řešení této práce.

### **Čestné prohlášení**

Prohlašuji, že jsem práci: **Řízení autonomního agenta pomocí neuroevoluce** vypracoval samostatně a veškeré použité prameny a informace uvádím v seznamu použité literatury. Souhlasím, aby moje práce byla zveřejněna v souladu s § 47b zákona č. 111/1998 Sb., o vysokých školách a o změně a doplnění dalších zákonů (zákon o vysokých školách), ve znění pozdějších předpisů, a v souladu s platnou *Směrnicí o zveřejňování vysokoškolských závěrečných prací*.

Jsem si vědom, že se na moji práci vztahuje zákon č. 121/2000 Sb., autorský zákon, a že Mendelova univerzita v Brně má právo na uzavření licenční smlouvy a užití této práce jako školního díla podle § 60 odst. 1 autorského zákona.

Dále se zavazuji, že před sepsáním licenční smlouvy o využití díla jinou osobou (subjektem) si vyžádám písemné stanovisko univerzity o tom, že předmětná licenční smlouva není v rozporu s oprávněnými zájmy univerzity, a zavazuji se uhradit případný příspěvek na úhradu nákladů spojených se vznikem díla, a to až do jejich skutečné výše.

V Brně dne 2. listopadu 2018

.....

**Abstract**

Autonomous agent control using neuroevolution

**Abstrakt**

Řízení autonomního agenta pomocí neuroevoluce

Tato práce se zabývá trénováním autonomního agenta - auta s pomocí algoritmu neuroevoluce. Toto zahrnuje tvorbu simulačního prostředí pro agenta, vhodným návrhem agenta (senzorů a řízení) a také návrhem fitness funkce

## Obsah

<b>1</b>	<b>Úvod a cíl práce</b>	<b>6</b>
1.1	Úvod do problematiky . . . . .	6
<b>2</b>	<b>Neuronové sítě</b>	<b>7</b>
2.1	Druhy úloh neuronových sítí . . . . .	7
2.2	Neuron . . . . .	7
	Aktivační funkce . . . . .	7
	Lineární funkce . . . . .	7
	Sigmoid . . . . .	8
	Tanh . . . . .	8
	RELU . . . . .	9
2.3	Genetické algoritmy . . . . .	9
2.4	Neuroevoluce . . . . .	9
<b>3</b>	<b>Vlastní práce</b>	<b>10</b>
3.1	Simulace . . . . .	10
3.2	Serverová část . . . . .	10
3.3	Klientská část . . . . .	10
3.4	Simulace . . . . .	10
<b>4</b>	<b>Reference</b>	<b>11</b>
	<b>Přílohy</b>	<b>12</b>
<b>A</b>	<b>CD se zdrojovým kódem</b>	<b>13</b>

# 1 Úvod a cíl práce

## 1.1 Úvod do problematiky

S růstem výpočetního výkonu a rozvojem **gpugpu** (paralelizace výpočtů na grafické kartě) se neuronové sítě ukázaly jako mocný nástroj pro řešení složitých problémů na které standardní metody umělé inteligence nestačily. K dalším možnostem

## 2 Neuronové sítě

Neuronové sítě jsou model strojového učení, který je volně založený na principu zvířecího mozku. (PATTERSON, Josh. 2017, s. 41)

### 2.1 Druhy úloh neuronových sítí

Neuronové sítě se používají především pro řešení regresních a klasifikačních problémů.

### 2.2 Neuron

Neuron je základní jednotka neuronových sítí, která je definovaná jako suma všech jejích vstupů a aplikace aktivační funkce.

$$\sigma(\sum_{i=0}^N \theta \cdot x_i + b)$$


#### Aktivační funkce

«««< HEAD Aktivační funkce se používá pro definování výstupu a zavedení nelinearity. Bez nich by byla neuronová síť schopna aproximovat pouze n-dimenzionální rovinu. (PATTERSON, Josh. 2017, s. 65)

Dalším využitím je omezení výstupních hodnot. Například aktivační funkce sigmoid se s oblibou používá u výstupní vrstvy neuronových sítí určených ke klasifikačním problémům, protože je to relace  $\mathbb{R} \rightarrow \{0..1\}$ , která se dá jednoduše jako "jistota" neuronu, že se jedná o výstup, který neuron reprezentuje. Podobně se dá uvažovat i o funkcích jako je například softmax a tanh, které také najdou hojně využití u klasifikačních problémů.

#### Lineární funkce


Vrací vstup, tak jak je. Využití najde především u vstupní vrstvy neuronové sítě a u neuronových sítí, které řeší regresní typy úloh.



$$f(x) = x$$

### Sigmoid

Sigmoid je aktivační funkce, která je schopná potlačit extrémní hodnoty




$$f(x) = \frac{1}{1 + e^{-x}}$$

### Tanh

Tanh je funkce obdobná sigmoidu. Hlavní rozdíl mezi ní a sigmoidem je ten, že její obor je v rozmezí -1 a 1 hodí se proto i pro záporná výstupy, které vyžadují záporná čísla. (PATTERSON, Josh. 2017, s. 67)






$$f(x) = \tanh(x)$$

## RELU

RELU je aktivační funkce, která je podobná lineární aktivační funkci s tím rozdílem, že pokud vstupní hodnota nepřesáhne určitého prahu výstupem je 0. Její hlavní výhodou je to, že zabraňuje problémům s takzvaným explodujícím gradientem (PATTERSON, Josh. 2017, s. 69)



$$f(x) = \begin{cases} x & x \geq 0 \\ 0 & x < 0 \end{cases}$$

## 2.3 Genetické algoritmy

## 2.4 Neuroevoluce

## **3 Vlastní práce**

### **3.1 Simulace**

### **3.2 Serverová část**

Serverová část slouží k

### **3.3 Klientská část**

### **3.4 Simulace**

«««< HEAD

## 4 Reference

BUDUMA, NIKHIL. *Fundamentals of deep learning: designing next-generation machine intelligence algorithms*. Sebastopol: O'Reilly, 2017. ISBN 978-149-1925-614..

PATTERSON, JOSH. *Deep learning : a practitioner's approach* *Deep learning : a practitioner's approach. 1*. Beijing ; Boston ; Farnham ; Sebastopol ; Tokyo: O'Reilly, 2017. ISBN 978-1-491-91425-0..

=====

## 5 Reference

BUDUMA, NIKHIL. *Fundamentals of deep learning: designing next-generation machine intelligence algorithms*. Sebastopol: O'Reilly, 2017. ISBN 978-149-1925-614..  
»»»> 308ebd913ef5d1adbdedac7ae60d045979caad51

## **Přílohy**

## **A CD se zdrojovým kódem**