

Mendelova univerzita v Brně
Provozně ekonomická fakulta

Řízení autonomního agenta pomocí neuroevoluce

Diplomová práce

Vedoucí práce:
Ing. Jiří Lýsek, Ph.D.

Bc. Martin Hnátek

Brno, 2018

Rád bych zde poděkoval svému vedoucímu Ing. Jiří Lýskovi, Ph.D. za jeho rady a čas, který mi věnoval při řešení této práce.

Čestné prohlášení

Prohlašuji, že jsem práci: **Řízení autonomního agenta pomocí neuroevoluce** vypracoval samostatně a veškeré použité prameny a informace uvádím v seznamu použité literatury. Souhlasím, aby moje práce byla zveřejněna v souladu s § 47b zákona č. 111/1998 Sb., o vysokých školách a o změně a doplnění dalších zákonů (zákon o vysokých školách), ve znění pozdějších předpisů, a v souladu s platnou *Směrnicí o zveřejňování vysokoškolských závěrečných prací*.

Jsem si vědom, že se na moji práci vztahuje zákon č. 121/2000 Sb., autorský zákon, a že Mendelova univerzita v Brně má právo na uzavření licenční smlouvy a užití této práce jako školního díla podle § 60 odst. 1 autorského zákona.

Dále se zavazuji, že před sepsáním licenční smlouvy o využití díla jinou osobou (subjektem) si vyžádám písemné stanovisko univerzity, že předmětná licenční smlouva není v rozporu s oprávněnými zájmy univerzity, a zavazuji se uhradit případný příspěvek na úhradu nákladů spojených se vznikem díla, a to až do jejich skutečné výše.

V Brně dne 6. listopadu 2018

.....

Abstract

Autonomous agent control using neuroevolution

Abstrakt

Řízení autonomního agenta pomocí neuroevoluce

Tato práce se zabývá trénováním autonomního agenta - auta s pomocí algoritmu neuroevoluce. Toto zahrnuje tvorbu simulačního prostředí pro agenta, vhodným návrhem agenta (senzorů a řízení) a také návrhem fitness funkce

Obsah

1	Úvod a cíl práce	6
1.1	Úvod do problematiky	6
1.2	Cíl práce	6
2	Neuronové sítě	7
2.1	Neuron	7
	Aktivační funkce	7
	Lineární funkce	7
	Sigmoid	8
	Tanh	8
	RELU	9
2.2	Genetické algoritmy	9
	Princip	10
	Kódování	10
	Křížení	10
	Mutace	10
	Selekce	11
2.3	Neuroevoluce	11
3	Vlastní práce	12
3.1	Simulace	12
	Fitness funkce	12
3.2	Serverová část	12
3.3	Klientská část	12
3.4	Simulace	12
4	Reference	13
	Přílohy	14
A	CD se zdrojovým kódem	15

1 Úvod a cíl práce

1.1 Úvod do problematiky

S růstem výpočetního výkonu a rozvojem **gpugpu** (paralelizace výpočtů na grafické kartě) se neuronové sítě ukázaly jako mocný nástroj pro řešení složitých problémů na které standardní metody umělé inteligence nestačily.

Další oblastí umělé inteligence, které nárůst masivní paralelizace prospěl jsou metaheuristiky, které mohou s nárůstem výpočetního výkonu v rozumném čase pokrýt stále větší stavový prostor a jsou tedy schopné rychle řešit stále složitější problémy. Neuroevoluce propojuje oba přístupy a využívá je ke generování topologií neuronových sítí a nastavení jejích vah. Výsledkem je neuronová síť, jejíž architektura lépe popisuje daný problém a lze jí aplikovat i na problémy na které by klasické neuronové sítě aplikovat nešly. Jedná se například o problémy u kterých je těžké získat trénovací data a nelze tedy neuronovou síť natrénovat klasickými metodami jako je backpropagace.

1.2 Cíl práce

Cílem této práce je navrhnout a pokusit se natrénovat autonomního agenta v simulovaném prostředí s pomocí algoritmu neuroevoluce.

2 Neuronové sítě

Neuronové sítě jsou model strojového učení, který je volně založený na principu zvířecího mozku. (PATTERSON, Josh. 2017, s. 41)

2.1 Neuron

Neuron je základní výpočetní jednotka neuronových sítí, která je definovaná jako suma všech jejích vstupů a aplikace aktivační funkce.

$$\sigma(\sum_{i=0}^N \theta_i \cdot x_i + b)$$

Kde:

1. σ - aktivační funkce
2. θ - skrytá váha pro daný vstup
3. b - bias neuronu

2.2 Vrstva

Vrstva je skupina neuronů se stejnou aktivační funkcí.


Aktivační funkce

Aktivační funkce se používá pro definování výstupu a zavedení nelinearity. Bez nich by byla neuronová síť schopna aproximovat pouze n-dimenzionální rovinu. (PATTERSON, Josh. 2017, s. 65)

Dalším využitím je omezení výstupních hodnot. Například aktivační funkce sigmoid se s oblibou používá u výstupní vrstvy neuronových sítí určených ke klasifikačním problémům, protože je to relace $\mathbb{R} \rightarrow \{0..1\}$, která se dá jednoduše jako "jistota" neuronu, že se jedná o výstup, který neuron reprezentuje. Podobně se dá uvažovat i o funkcích jako je například softmax a tanh, které také najdou hojné využití u klasifikačních problémů.

Lineární funkce


Vrací vstup, tak jak je. Využití najde především u vstupní vrstvy neuronové sítě a u neuronových sítí, které řeší regresní typy úloh.



$$f(x) = x$$

Sigmoid


Sigmoid je aktivační funkce, která je schopná potlačit extrémní hodnoty



$$f(x) = \frac{1}{1 + e^{-x}}$$

Tanh


Tanh je funkce obdobná sigmoidu. Hlavní rozdíl mezi ní a sigmoidem je ten, že její obor je v rozmezí -1 a 1 hodí se proto i pro záporná výstupy, které vyžadují záporná čísla. (PATTERSON, Josh. 2017, s. 67)



$$f(x) = \tanh(x)$$

RELU

RELU je aktivační funkce, která je podobná lineární aktivační funkci s tím rozdílem, že pokud vstupní hodnota nepřesáhne určitého prahu výstupem je 0. Její hlavní výhodou je to, že zabraňuje problémům s takzvaným explodujícím gradientem (PATTERSON, Josh. 2017, s. 69)



$$f(x) = \begin{cases} x & x \geq 0, \\ 0 & x < 0, \end{cases}$$

2.3 Genetické algoritmy

Genetické algoritmy slouží k řízenému prohledávání stavového prostoru založené na teorii evoluce.

Princip

Základní myšlenka spočívá ve vygenerování náhodných jedinců (řešení problému) a jejich postupné zlepšování s pomocí operací křížení a mutace. Proces zlepšování genomů probíhá na základě jeho hodnocení (fitness).

Samotný algoritmus pak lze rozdělit na následující kroky (MITCHELL, Melanie., 1996, s. 12)

1. Vygeneruj náhodnou populaci o n chromozomech
2. Pro každý chromozom spočítej jeho fitness
3. Opakuj n krát
 - a) Vyber pár chromozomů na základě jejich ohodnocení (selekce)
 - b) S určitou pravděpodobností p_c rozděl pár chromozomů na náhodném místě a jejich spojení.
 - c) S určitou pravděpodobností mutuj daného jedince
4. Nahraď současnou populaci populací, která vznikla předchozím krokem
5. Jdi na krok 2

Kódování

Způsob zápisu řešení problému. Existuje mnoho různých kódování a každý má své výhody a nevýhody. Zde je seznam několika nepoužívanějších kódování (HYNEK, Josef., 2008, s. 42-43):

1. Binární - řetězec bitů, který může například reprezentovat jednu nebo více numerických hodnot.
2. Realná čísla - Jedno nebo více reálných čísel
3. Kombinatorické - Může být například seznam čísel označujících

Křížení

Křížení je operátor, který kombinuje dva jedince do jednoho. Jeho implementace je samozřejmě závislá na

Mutace

Mutace náhodně modifikuje chromozom a zavádí tak do populace variaci.

Selekce

Selekce je proces výběru dvou jedinců na něž jsou později aplikovány genetické operátory jako je křížení a mutace.

2.4 Neuroevoluce

3 Vlastní práce

Vlastní práce se skládá ze dvou částí: klientská část, která slouží k vizualizaci algoritmu a zobrazení výsledků, a serverová část. Serverová část pro maximální zrychlení simulace.

3.1 Simulace

Fitness funkce

Fitness funkce je důležitou součástí simulace, která zásadně ovlivňuje chování výsledných agentů a je tedy nutné jí volit vhodně.

3.2 Serverová část

Serverová část obaluje simulaci do jednoduchého REST api.

3.3 Klientská část

3.4 Simulace

4 Reference

- BUDUMA, NIKHIL. *Fundamentals of deep learning: designing next-generation machine intelligence algorithms*. Sebastopol: O'Reilly, 2017. ISBN 978-149-1925-614..
- PATTERSON, JOSH. *Deep learning : a practitioner's approach Deep learning : a practitioner's approach. 1*. Beijing ; Boston ; Farnham ; Sebastopol ; Tokyo: O'Reilly, 2017. ISBN 978-1-491-91425-0..
- MITCHELL, MELANIE. *An introduction to genetic algorithms*. Cambridge: Bradford Book, c1996. ISBN 0-262-13316-4..
- HYNEK, JOSEF. *Genetické algoritmy a genetické programování*. Praha: Grada, 2008. Průvodce (Grada). ISBN 978-80-247-2695-3..

Přílohy

A CD se zdrojovým kódem